

1.2.2

Л.Ю. Емалетдинова д-р техн. наук, Н.Р. Вильданов, А.С. Катасев д-р техн. наук

Казанский национальный исследовательский технический университет
им. А.Н. Туполева-КАИ, институт компьютерных технологий и защиты информации,
кафедра прикладной математики и информатики,
Казань, lilia@stcline.ru

ИСПОЛЬЗОВАНИЕ НЕЙРОСЕТЕВОЙ МОДЕЛИ TCN-LSTM ДЛЯ ПРОГНОЗИРОВАНИЯ ЗНАЧЕНИЙ ВРЕМЕННОГО РЯДА

В работе были разработаны модели решения задачи прогнозирования значений временного ряда суточной температуры на основе архитектур рекуррентной нейронной сети, сверточной нейронной сети, а также их комбинирования. Проведен сравнительный анализ результатов прогнозирования с помощью построенных моделей.

Ключевые слова: *прогнозирование, временной ряд, временные сверточные сети, сети долгой краткосрочной памяти.*

При прогнозировании значений временного ряда широкое применение находят нейросетевые модели различных архитектур. Так, в статьях [1-6] приводятся результаты прогнозирования значений различных временных рядов (биржевого индекса, котировок валютных пар, числа погибших на пожарах и др.) с использованием персептронов, рекуррентных и сверточных нейросетей. На основе изученных исследований можно сделать вывод о том, что, хотя нейросетевые модели способны обеспечивать лучшие результаты по сравнению с традиционными математическими моделями, важным является вопрос выбора архитектуры и параметров используемой модели.

Рекуррентные нейронные сети представляют собой вид нейронных сетей, имеющих обратные связи между элементами и реализующих тем самым в модели функцию памяти. Вместе с тем, необходимо учитывать возрастающую сложность обучения таких сетей. Использование большего числа элементов временных задержек в архитектуре позволяет учитывать более долгосрочные тренды в данных, однако это приводит к возрастающей вычислительной сложности подобных моделей.

Существует большое множество различных архитектур рекуррентных нейронных сетей. Среди рекуррентных сетей можно отметить сеть долгой краткосрочной памяти (Long short-term memory - LSTM), решающую проблему учета долгосрочных трендов и вычислительной сложности реализуемых в модели алгоритмов. Сеть LSTM использует для прогнозирования в дополнение к вектору входных данных выходные прогнозные данные с единичным временным лагом, а также специальное значение, представляющее собой состояние внутренней памяти модели. При этом архитектура LSTM сети обеспечивает запоминание значений, как на короткие, так и на длинные временные промежутки. Модель сети LSTM может быть описана с помощью зависимостей представленных в работе [7] и представлена на рис 1. В процессе обучения сети LSTM определяются матрицы параметров и вектор константы.

Структура сверточных нейронных сетей (CNN) состоит из сверточных и субдискретизирующих слоев. Особенностью CNN является их способность к выделению признаков в данных. Архитектура временной сверточной сети (TCN) состоит из кодировщика и декодировщика, реализованных с помощью последовательности сверточных слоев. Пример структуры приведен на рис. 2. При этом в TCN операция свертки в сверточных слоях заменена на расширенную каузальную свертку [8]. При параметре расширения $d = 1$ расширенная свертка сводится к обычной.




Рис. 1 – Нейросетевая модель LSTM, где x_t , y_t – входной и выходной вектор, f_t – вес запоминания старой информации; i_t – вес получения новой информации; o_t – вес вектора состояний; C_t – вектор состояний, W, U, b – матрицы параметров и вектор константы, σ, th – функции активации: сигмоидная и гиперболический тангенс, * – произведение Адамара.

Результатом работы кодировщика является набор временных признаков исходного вектора входных данных, на основе которых декодировщик строит прогнозные данные.

Поскольку модель LSTM учитывает долгосрочные тренды предыдущих значений временного ряда, а модель TCN выделяет его временные признаки, то целесообразно рассмотреть комбинацию моделей. Предлагается модель LSTM использовать между кодировщиком и декодировщиком (рис.3).




Рис. 2 – Пример модели TCN



Рис. 3 - Схема TCN- LSTM

Идея модели TCN-LSTM заключается в том, что на основе значений временных признаков полученных с помощью кодировщика, сеть долгой краткосрочной памяти прогнозирует значения временных признаков для вектора выходных значений. Затем на основе полученных спрогнозированных значений признаков декодировщик строит прогнозные значения данных временного ряда.

Рассмотрим результаты прогнозирования временного ряда с использованием сетей LSTM, TCN, TCN-LSTM на примере временного ряда посуточной температуры. Для обучения и тестирования нейронных сетей были выбраны данные о посуточной температуре в г. Сургут с 2018 г. до 2021 г. В качестве входных данных для исследуемых моделей использовался вектор из 7 последовательных значений температуры. Результаты оценки точности рассматриваемых моделей представлены в таблице.

Таблица - Результаты оценки точности обученных нейронных сетей

Размер входного/выходного векторов	Архитектура сети		
	LSTM	TCN	TCN-LSTM
7/1	0.307	0.315	0.157
7/4	0.606	0.465	0.308
7/7	0.584	0.532	0.446

Из результатов представленных в таблице видно, что предложенная модель TCN-LSTM показывает лучшие результаты прогнозирования с горизонтами 1, 4, 7 по сравнению с LSTM и TCN.

Список литературы

1. Лабинский А.Ю. Особенности использования нейронной сети для прогнозирования временных рядов [Текст] / А.Ю. Лабинский // Вестник Санкт-петербургского университета – 2018. – №1. – С. 40-45.
2. Верзунов С.Н. Применение глубоких нейронных сетей для краткосрочного прогноза дальности видимости [Текст] / С.Н. Верзунов // Проблемы автоматизации и управления – 2019. – №1. – С. 118-130.
3. Емалетдинова Л.Ю. Нейросетевое моделирование задачи прогнозирования значений временного ряда [Текст] / Л.Ю. Емалетдинова, А.Н. Кабирова, Н.Р. Вильданов // «Вестник технологического университета». - 2022. - Т.25, №10. С. 101-106
4. Temporal Convolutional Networks Applied to Energy-Related Time Series Forecasting [Текст] / P. Lara-Benitez, M. Carranza-Garcia, J.M. Luna-Romera, J.C. Riquelme // Applied sciences – 2020. – №10.
5. An Advanced CNN-LSTM Model for Cryptocurrency Forecasting [Текст] / L.E. Livieris, N. Kiriakidou, S. Stavroyiannis, P. Pintelas // Electronics – 2021. – №10.
6. Temporal convolutional neural (TCN) network for an effective weather forecasting using time-series data from the local weather station [Текст] / P. Hewage, A. Behera, M. Trovati [и др.] // Soft Computing – 2020. – V.24. – P.16453-16482.
7. Hochreiter S., Long Short-term Memory [Текст] / S. Hochreiter, J. Schmidhuber // Neural Computation. – 1997. – V.9. – P.1735-1780.
8. Temporal Convolutional Networks for Action Segmentation and Detection [Электронный ресурс] / C. S. Lea, M. D. Flynn, R. Vidal, A. Reiter [и др.] // Электронный архив arXiv.org. – URL: <https://arxiv.org/abs/1611.05267> (Дата обращения 01.04.2023).