

УДК 004

ПРИМЕНЕНИЕ МОДЕЛИ TCN-LSTM ДЛЯ ДЕТЕКТИРОВАНИЯ АНОМАЛИЙ ВО ВРЕМЕННЫХ РЯДАХ

Н.Р. Вильданов¹, Л.Ю. Емалетдинова²

Казанский национальный исследовательский технический университет им. А.Н. Туполева, Россия, Казань,

¹vildanov.n98@gmail, ²lilia@stcline.ru,

Аннотация. Выполнено сравнение результатов работы моделей TCN и TCN-LSTM при решении задачи обнаружения аномалий во временных рядах.

Ключевые слова: аномалия, временной ряд, прогнозирование, нейросетевой метод, сверточная нейронная сеть.

APPLICATION OF THE TCN-LSTM MODEL FOR DETECTING ANOMALIES IN TIME SERIES

N.R. Vildanov¹, L.Yu. Emaletdinova²

Kazan National Research Technical University named after A.N. Tupolev, Russia, Kazan,

¹vildanov.n98@gmail.com, ²lilia@stcline.ru

Abstract. The article provides a comparison of the results of the TCN and TCN-LSTM models when solving the problem of detecting anomalies in time series

Keywords: anomaly, time series, forecasting, neural network method, convolutional neural network.

Для цитирования: Вильданов Н.Р., Емалетдинова Л.Ю. Применение модели TCN-LSTM для детектирования аномалий во временных рядах // Математические методы в технологиях и технике. 2024. № 9. С. 82-85.

Введение. Временной ряд представляет набор данных, содержащих значения некоторой переменной в разные моменты времени. Обработка временного ряда, в общем случае, не привязана к конкретной предметной области, что обуславливает возможность ее использования её методов при анализе данных в различных прикладных областях. Одной из важных задач при обработке временных рядов является обнаружение аномальных значений. Существует множество различных математических методов обнаружения аномалий во временных рядах [1]. Среди них представляют интерес методы, основанные на искусственных нейронных сетях. Для детектирования аномалий используются различные подходы с применением нейронных сетей, в том числе подход, основанный на прогнозировании значений временного ряда [2].

В работе [3] описана модель прогнозирования TCN (Temporal Convolutional Network), представляющая собой сверточную нейронную сеть и реализующая технологию кодировщик-декодировщик. В работе [4] предложена комбинационная модель TCN-LSTM. Ее особенностью является наличие между слоями кодировщика и декодировщика сети TCN рекуррентного слоя LSTM, прогнозирующего долгосрочные тренды признаков фрейма временного ряда, поступающих из слоев кодировщика сети TCN. Полученные прогнозные значения признаков передаются на вход слоев декодировщика сети TCN, на выходе которых получается прогнозное значение временного ряда.

В настоящей работе проводится сравнение результатов работы моделей TCN и TCN-LSTM при решении задачи обнаружения аномалий. Прогнозные модели TCN и TCN-LSTM обучались на наборе данных, содержащем сведения об автомобильном трафике определенного участка дороги, зафиксированном в течение каждого пятиминутного интервала времени. Сравнение результатов прогнозирования, осуществляемого с использованием этих моделей, производилось на тестовом

множестве из этого набора данных. Для имитации аномалий 10% значений в тестовом множестве уменьшены в два раза, что соответствует сокращению автомобильного движения («автомобильной пробки») в течение пятиминутного промежутка времени.

При прогнозировании значений, содержащих аномалии, если модель распознавала значение как аномальное, при дальнейшем прогнозировании вместо данного значения использовалось прогнозное.

Результаты прогнозов. На рис. 1 и 2 представлены результаты прогнозирования с использованием моделей TCN, TCN-LSTM, а также график исходных данных.




Рис. 1. Результаты прогнозирования тренировочной части временного ряда с использованием моделей TCN-LSTM и TCN




Рис. 2. Результаты прогнозирования тестовой части временного ряда с аномальными значениями с использованием моделей TCN-LSTM и TCN

Как видно из графиков на рис. 1 и рис. 2 прогнозные значения модели TCN склонны повторять вид аномалии, встреченной ранее. При этом модифицированная модель на основе использования рекуррентного слоя способна сохранять

долгосрочные тренды и, таким образом, менее склонна к формированию ошибочных прогнозов после встречи с аномальными значениями.

Для принятия решения об аномальности значения временного ряда на основе его текущего и прогнозного значений используется следующее решающее правило:

$$\text{если } |x(t) - p(t)| > \varepsilon, \text{ то } x(t) - \text{аномальное.} \quad (1)$$

Здесь $x(t), p(t)$ – соответственно нормализованное текущее и прогнозные значения временного ряда, ε заданное значение порога: $0 \leq \varepsilon \leq 1$.

В результате экспериментальных исследований вычислены FPR (false positive rate) – частота ложноположительных оценок и TPR (true positive rate) – частота истинно-положительных оценок:

$$FPR = \frac{FP}{FP+TP}, TPR = \frac{TP}{TP+FN},$$

где FP (false positive) – число неаномальных значений, распознанных как аномалии;

TP (true positive) – число аномальных значений, распознанных как аномалии;

FN (false negative) – число аномальных значений, распознанных как неаномальные;

TN (true negative) – число неаномальных значений, распознанных как неаномальные.

На основе поведенных расчетов построены графики зависимости частот ложно- и истинно-положительных оценок в зависимости от заданного значения порога ε для принятия решения об аномальности с использованием моделей TCN-LSTM и TCN (рис. 3 и 4).




Рис. 3. Зависимость частоты ложноположительных оценок FPR от заданного значения порога ε




Рис. 4. Зависимость частоты истинно-положительных оценок TPR от заданного значения порога ε

Графическое отражение проведенных расчетов (рис. 1–4) показывает, что принятие решения об аномальности (1) с использованием комбинационной модели TCN-LSTM при определенных значениях порога ε позволяет более точно выявлять аномальные значения временного ряда и меньше ошибаться, принимая неаномальные значения за аномальные. Поэтому можно сделать вывод, что комбинационная модель TCN-LSTM показывает лучшие результаты по сравнению с моделью TCN.

На основе полученных данных построены ROC-кривые (рис. 5).




Рис. 5. ROC-кривые моделей принятия решений на основе прогнозных нейронных сетей

Взаимное расположение ROC-кривых указывает на их сравнительную эффективность. Кривая для сети TCN-LSTM свидетельствует о большей предсказательной способности этой модели.

Заключение. Для численного сравнения способности нейросетей TCN-LSTM и TCN детектировать аномалии для каждой из них рассчитан коэффициент Джини G , определяемый по формуле $G = 2S - 1$, где S – площадь под ROC-кривой:

$$G_{TCN-LSTM} = 982; G_{TCN} = 0.949.$$

Полученные значения коэффициентов также свидетельствуют о лучшей способности прогнозной нейросети TCN-LSTM выявлять аномалии.

Библиографический список

1. Голубчикова И.С. Исследование применимости методов обнаружения аномалий во временных рядах // Электронные средства и системы управления. Материалы докладов Международной научно-практической конференции. 2017. № 1-2. С. 160-163.
2. Guansong P., Chunhua S., Longbing C., Anton H. Deep Learning for Anomaly Detection: A Review // ACM Computing Surveys. 2012. Vol. 54, pp. 1-38. DOI: 10.1145/3439950.
3. Mezina A. Network Anomaly Detection with Temporal Convolutional Network and U-Net Model // IEEE Access. 2021. Vol. 9, pp. 143608-143622.
4. Емалетдинова Л.Ю., Вильданов Н.Р., Катасев А.С. Использование нейросетевой модели TCN-LSTM для прогнозирования значений временного ряда // Научно-технический вестник Поволжья. 2023. № 6. С. 62-64.