

Научная статья

УДК 004.94

doi:10.17213/0136-3360-2025-3-130-136

Математическое моделирование и прогнозирование значений электропотребления на основе алгоритма деревьев решений

Светлана Александровна Вялкова[✉], Ольга Александровна Корнюкова, Иван Иванович Надтока

Южно-Российский государственный политехнический университет (НПИ) имени М.И. Платова, г. Новочеркасск, Россия, [✉]mazaeva_sveta@mail.ru

Аннотация. Проанализированы средние за сутки значения суточных графиков электропотребления, температуры воздуха, естественной освещенности, облачности и осадков г. Москвы. Получены зависимости электропотребления от температуры воздуха, облачности и освещенности. Предложена модель, сформированная на основе машинного обучения с использованием алгоритма регрессионных деревьев решений с учетом данных по температуре воздуха, облачности и естественной освещенности. Спрогнозированы значения временного ряда электропотребления с учётом метеофакторов на основе простых правил принятия решений, выведенных из характеристик исходных данных. Представлены результаты прогнозов среднесуточных значений электропотребления, с использованием прогнозной модели на основе метода регрессионных деревьев решений с учётом данных по температуре воздуха, облачности и естественной освещенности для выбранных периодов в апреле, июне и октябре. Разработанный алгоритм позволяет учитывать сезонные закономерности между суточными графиками электропотребления и метеофакторами. Результаты прогнозирования среднесуточных значений электропотребления показали, что в большинстве тестовых примеров получены значения ошибок не более 5 %. Для реализации математических моделей анализа и прогнозирования временных рядов использованы библиотеки языка *Python*. При анализе и преобразованиях временных рядов метеофакторов применены данные метеорологического программно-аппаратного комплекса ПАК «Метео».

Ключевые слова: прогнозирование электропотребления, активная мощность, температура воздуха, естественная освещенность, облачность, машинное обучение, алгоритм регрессионных деревьев решений

Для цитирования: Вялкова С.А., Корнюкова О.А., Надтока И.И. Математическое моделирование и прогнозирование значений электропотребления на основе алгоритма деревьев решений // Изв. вузов. Электромеханика. 2025. Т. 68. №3. С. 130-136. <https://doi.org/10.17213/0136-3360-2025-3-130-136>.

Original article

Mathematical modeling and forecasting of power consumption values based on the decision trees algorithm

Svetlana A. Vyalkova[✉], Olga A. Korniyukova, Ivan I. Nadтока

Platov South-Russian State Polytechnic University (NPI), Novocherkassk, Russian Federation, [✉]mazaeva_sveta@mail.ru

Abstract. The article presents the results of the analysis of average daily values of daily graphs of electricity consumption, air temperature, natural light, cloudiness and precipitation in Moscow. The dependences of electricity consumption on air temperature, cloudiness, precipitation and illumination are obtained. A model is proposed based on machine learning using the algorithm of decision trees of regression taking into account data on air temperature, cloudiness and natural light. This model predicts the values of the time series of power consumption taking into account meteorological factors based on simple decision-making rules derived from the characteristics of the original data. The article presents the results of forecasts of average daily values of power consumption using a forecast model based on the decision tree method for selected periods in April, June and October. The results of forecasting the average daily values of power consumption show that in most test examples the obtained error values are no more than 5 %. In addition the developed algorithm allows using seasonal patterns between daily graphs of power consumption and meteorological factors. Python libraries were used to implement the modeling of mathematical models for analyzing and forecasting time series. Data

from the meteorological software and hardware complex PAK "Meteo" were used in the analysis and transformation of time series of meteorological factors.

Keywords: forecasting electricity consumption, power consumption, air temperature, natural light, cloudiness, machine learning, regression decision trees algorithm

For citation: Vyalkova S.A., Korniyukova O.A., Nadtocha I.I. Mathematical modeling and forecasting of power consumption values based on the decision trees algorithm. *Izvestiya Vysshikh Uchebnykh Zavedenii. Elektromekhanika* = *Russian Electromechanics*. 2025;68(3):130-136. (In Russ.). <https://doi.org/10.17213/0136-3360-2025-3-130-136>.

Введение

Для планирования электроэнергетических режимов работы энергообъектов и энергосистем и поддержания высокого качества управления электроснабжением необходимо выполнение прогнозирования электропотребления. Повышение точности прогнозирования позволяет улучшить качество работы и является обязательным элементом для служб диспетчерского управления. Снижение точности прогнозов электропотребления может стать причиной аварий в электрических сетях.

На процесс электропотребления влияют такие факторы как температура воздуха, облачность, естественная освещенность и др. [1, 2], что значительно усложняет задачу прогнозирования [3, 4].

При прогнозировании среднесуточных значений активной мощности используется большое количество методов, основанных на искусственных нейронных сетях и др. [5, 6]. Основными метеофакторами, влияющими на активную мощность и учитываемыми в прогнозных моделях, являются температура воздуха, естественная освещенность и облачность [7–9].

Перспективным направлением при прогнозировании суточных графиков активной мощности энергообъединений и энергосистем является использование алгоритма регрессионных деревьев решений (*Decision Tree*) [10]. Использование алгоритма регрессионных деревьев решений для прогнозного анализа дает несколько преимуществ: он может быть применен как для задач регрессии, так и для классификации [10–12]. Его можно использовать для классификации нелинейно разделимой выборки [13]. Цель состоит в том, чтобы создать модель, которая прогнозирует значение временного ряда, используя простые правила принятия решений, выведенные из характеристик данных. Дерево решений можно рассматривать как кусочно-линейное приближение [14, 15].

В настоящей статье прогнозирование среднесуточных значений активной мощности выполнено с помощью контролируемого машинного обучения на основе алгоритма регрессионных деревьев решений, реализованного на языке

Python в библиотеке *DecisionTreeRegressor*. При применении и анализе этого алгоритма существует особенность использования, на которую следует указать: отсутствует возможность экстраполировать или выполнять прогнозы вне диапазона значений обучающих данных [16, 17].

Взаимосвязи между данными электропотребления и метеофакторами

При исследовании использованы данные в виде годовых графиков среднесуточных значений по активной мощности, температуре воздуха, естественной освещенности и облачности, полученные из архивов Московского РДУ за 2018 и 2019 гг. В качестве данных облачности использованы среднесуточные значения, предоставляемые программным комплексом ПAK «Метео»¹.

Для сбора данных естественной освещенности и формирования предыстории её значений использована автоматическая система контроля освещенности на территории г. Москвы, обеспечивающая решение задачи формирования архивов показателей освещенности для их последующего использования в системе прогнозирования мощности с учетом метеофакторов [18].

Учет температуры воздуха, облачности и естественной освещенности в описываемой прогнозной модели осуществлён путем добавления данных среднесуточных значений метеофакторов $\bar{\Theta}(t)$, $\bar{O}(t)$, $\bar{E}(t)$ в качестве входных данных для метода регрессионных деревьев решений [10].

Длина входного интервала d алгоритма прогнозирования для разных типов суток составила:

- для рабочих $d = 90$ сут (3 месяца);
- для выходных, послепраздничных, предпраздничных, нерегулярных (в днях при переносе праздничных дней) $d = 90$ сут (6 месяцев);
- для праздничных d равно количеству праздников в прогнозируемом месяце за предыдущий год.

¹Методика контроля точности прогноза потребления: Распоряжение руководителя оперативного штаба по совершенствованию конкурентного балансирующего рынка ОАО «Системный оператор единой энергетической системы» от 14 апреля 2011 № 132.

Среднесуточные значения активной мощности за 2018 г. показаны на рис. 1. В январе значения мощности достигают максимумов, к концу июня постепенно снижаются и в конце октября начинают возрастать. Таким образом, годовой график можно разбить на три периода: возрастающий – с октября до февраля; убывающий – с конца февраля до июня; площадка – с июня по октябрь. В летние месяцы иногда наблюдаются увеличения средних значений мощности, связанные с периодами аномально высоких температур воздуха и использованием кондиционеров. Существует

недельная периодичность в годовом графике средних значений активной мощности, проявляющаяся снижением мощности в выходные и праздничные дни. Подобные закономерности имеют место и в других энергосистемах [5, 6, 18].

На рис. 2 представлена зависимость среднесуточной активной мощности от среднесуточной температуры воздуха за период с 01.01.2018 по 31.12.2018 г. Точками показаны величины среднесуточной активной мощности при различных значениях среднесуточной температуры, а также график уравнения регрессии $\bar{P}(\Theta)$ (штриховая линия).




Рис. 1. График среднесуточных значений активной мощности с 1.01.2018 по 31.12.2018 г.

Fig. 1. Graph of average daily values of active power from 01.01.2018 to 31.12.2018




Рис. 2. Зависимость средней за сутки мощности от среднесуточной температуры воздуха для г. Москвы за период с 01.01.2018 по 31.12.2018 г.

Fig. 2. Average daily power versus average daily air temperature for Moscow for the period from 01.01.2018 to 31.12.2018

Коэффициент детерминации в целом, по всей совокупности данных для 2018 г., имеет значение, близкое к единице, и равен $R^2 = 0,9$, что свидетельствует о высокой взаимосвязи между среднесуточными значениями активной мощности и среднесуточной температурой воздуха.

На основе анализа данных графика рис. 2 сделаны выводы о том, что существует тенденция роста среднесуточной активной мощности при среднесуточных температурах выше $+19^\circ\text{C}$. В диапазоне среднесуточных температур от -8 до $+19^\circ\text{C}$ наблюдается общая тенденция уменьшения мощности.

Матрица исходных данных X сформирована из значений временных рядов $\bar{P}(t)$, $\bar{\Theta}(t)$, $\bar{E}(t)$, $\bar{O}(t)$ и имеет следующий вид:

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1j} & \dots & x_{1N} \\ x_{21} & x_{22} & \dots & x_{2l} & \dots & x_{2N} \\ x_{31} & x_{32} & \dots & x_{3j} & \dots & x_{3N} \\ x_{41} & x_{42} & \dots & x_{4j} & \dots & x_{4N} \end{bmatrix},$$

где x_{1j} , x_{2j} , x_{3j} , x_{4j} – значения $\bar{P}(t)$, $\bar{\Theta}(t)$, $\bar{E}(t)$, $\bar{O}(t)$ соответственно, $j = 1, \dots, N$ – номер суток, N – количество суток.

Для вычисления корреляционной матрицы необходимо преобразовать матрицу данных X в центрированную матрицу Y . Элементы y_{ij} центрированной матрицы Y определим следующим образом:

$$y_{ij} = x_{ij} - m_{xi},$$

где $m_{xi} = \frac{1}{N} \sum_{j=1}^N x_{ij}$ – математическое ожидание

элементов i -й строки матрицы X .

Корреляционную матрицу рассчитаем по формуле

$$K = \frac{YY^T}{(N-1)}.$$

Элементы k_{rs} ($r = 1, \dots, 4$; $s = 1, \dots, 4$) матрицы K вычислим по формуле

$$k_{rs} = \frac{1}{(N-1)} \sum_{j=1}^N y_{rj} y_{js}.$$

Матрицу K представим в виде матрицы коэффициентов корреляции K^* , элементы которой определяются следующим образом:

$$k_{rs}^* = \frac{k_{rs}}{\sigma_{xr} \sigma_{xs}},$$

где σ_{xr} , σ_{xs} – среднеквадратические отклонения для данных r -й и s -й строк матрицы Y , которые определяются по формуле

$$\sigma_{xi} = \sqrt{\frac{1}{(N-1)} \sum_{j=1}^N (x_{ij} - m_{xi})^2}.$$

Ниже представлены результаты расчетов числовых значений элементов корреляционной матрицы K^* для выборки данных длительностью $N = 60$ дней с 1.01.2018 по 1.03.2018 г.:

$$K^* = \begin{bmatrix} 1,00 & -0,89 & -0,71 & 0,37 \\ -0,89 & 1,00 & 0,71 & -0,38 \\ -0,71 & 0,71 & 1,00 & -0,77 \\ 0,37 & -0,38 & -0,77 & 1,00 \end{bmatrix}.$$

Значения соответствующих элементов матрицы K^* иллюстрируют сильные отрицательные взаимосвязи между $\bar{P}(t)$ и $\bar{\Theta}(t)$ ($k_{12}^* = k_{21}^* = -0,89$), между $\bar{P}(t)$ и $\bar{E}(t)$ ($k_{13}^* = k_{31}^* = -0,71$) и слабую положительную взаимосвязь между $\bar{P}(t)$ и $\bar{O}(t)$ ($k_{14}^* = k_{41}^* = 0,37$). Далее полученные взаимосвязи использованы в алгоритме регрессионных деревьев решений в качестве значимых параметров при прогнозировании активной мощности.

Прогнозирование активной мощности при помощи алгоритма регрессионных деревьев решений

В начале алгоритма регрессионных деревьев решений для каждого свойства в наборе данных формируется узел, а наиболее важное свойство помещается в корневой узел. Оценка начинается с корневого узла и продвигается вниз по дереву, следуя за узлом, который соответствует заданному условию или «решению». Этот процесс продолжается до тех пор, пока не будет достигнут конечный узел, содержащий прогноз или результат дерева решений.

Алгоритм регрессионных деревьев решений для прогнозирования электропотребления в Python [18] состоит из следующих шагов:

1. *Сбор данных.* Выбор исходных данных о различных факторах, которые могут влиять на активную мощность. Например, время суток, день недели, погодные условия (температура, освещенность, облачность), энергопотребление в прошлые периоды и другие факторы, которые могут быть релевантными.

2. *Предобработка данных.* Подготовка данных для обучения алгоритма. Включает в себя удаление выбросов, заполнение пропущенных значений, масштабирование или нормализацию признаков и создание новых признаков, если это необходимо.

3. *Разделение данных.* Разделение данных на обучающий и тестовый наборы. Обучающий набор будет использоваться для обучения модели, а тестовый набор – для оценки ее производительности и точности прогнозирования.




Рис. 3. Пример прогноза среднесуточных значений активной мощности с 4.06.2018 по 16.06.2018 г.: 1 – фактические значения, МВт; 2 – прогнозные значения, МВт

Fig. 3. Example of a forecast of average daily active power values from June 4, 2018 to June 16, 2018: 1 – actual values, MW; 2 – forecast values, MW

4. *Построение модели регрессионного дерева решений.* Обучение алгоритма деревьев регрессии на обучающем наборе данных. В этом алгоритме каждый узел дерева представляет собой разделение признака, которое максимизирует уменьшение среднеквадратичной ошибки (*MSE – mean squared error*, англ.). Каждый лист дерева содержит предсказанное значение целевой переменной p .

5. *Оценка модели.* Производительность модели оценивается на тестовом наборе данных с помощью метрик, таких как средняя абсолютная ошибка (*MAE – mean absolute error*, англ.), *MSE* или коэффициент детерминации R^2 .

6. *Улучшение модели.* Применение различных методов для улучшения производительности модели, таких как отбор признаков, настройка гиперпараметров, использование ансамблей деревьев решений и т.д.

7. *Прогнозирование активной мощности.* Применение обученной модели для прогнозирования активной мощности на новых или будущих данных.

Для получения удовлетворительных результатов необходимо повторять шаги 4–7. Алгоритм прогнозирования подробно описан в работах [10, 12].

Результаты прогнозирования суточных графиков активной мощности

Среднесрочное прогнозирование активной мощности при помощи алгоритма дерева решений с использованием описанной выше методики осуществлено для выбранных периодов с 21.10.2018 по 3.11.2018 г. и с 21.10.2019 по 3.11.2019 г.

Качество прогноза оценивалось по средней относительной процентной ошибке (*MAPE – mean absolute percentage error*, англ.):

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|P_{\Phi} - P_M|}{P_{\Phi}} 100\%,$$

где n – число наблюдений, $n = 24$ – число суточных измерений; i – номер часа; $P_{\Phi i}$ – фактическое значение для i -го часа; P_{Mi} – значение, полученное с помощью модели для i -го часа [14].

Фактический и прогнозный графики среднесуточного значения электропотребления представлены на рис. 3.

Средняя ошибка прогнозирования значений активной мощности *MAPE* за период с 4.06.2018 по 16.06.2018 г. составила 1,24 %. Минимальное значение *MAPE* = 0,13 %, максимальное *MAPE* = 3,07 %.

Аналогично выполнено прогнозирование для выбранных периодов в апреле, июне, октябре 2019 г. Средняя ошибка *MAPE* за все выбранные периоды составила 1,98 %. Минимальная ошибка получена для периода в июне 2019 г. – *MAPE* = 0,11 %, максимальная – *MAPE* = 4,24 % в период с 1.04.2018 по 10.04.2018 г., когда метеофакторы резко изменяли свои значения, что подчёркивает необходимость уточнения прогнозной модели.

Заключение

1. Проведен анализ временных рядов активной мощности и температуры воздуха. Рассмотрены основные тенденции изменения среднесуточных значений активной мощности в г. Москве за период с 2018 по 2019 гг. Временной ряд

активной мощности в течение года имеет общую трендовую составляющую, связанную с ростом (снижением) в течение года электропотребления и сезонными колебаниями. В зимние месяцы уровень мощности выше, чем в летние.

2. Установлена высокая взаимосвязь между среднесуточными значениями активной мощности г. Москвы и метеофакторами (температурой воздуха, облачностью и естественной освещенностью).

3. Предложенный алгоритм регрессионных деревьев решений для прогнозирования средне-

суточных значений активной мощности для г. Москвы с учетом метеофакторов дает результаты средней абсолютной процентной ошибки в исследуемых периодах 2018 и 2019 гг. не более 2 %, а минимальной – не более 5 %.

4. Для повышения точности прогнозирования активной мощности в энергосистеме с использованием метода регрессионных деревьев решений необходимо учитывать долгосрочные прогнозы погоды, планы ввода новых генерирующих мощностей и перспективы развития экономики мегаполиса, для которого выполняется прогноз.

Список источников

1. Надтока И.И., Губский С.О. Анализ зависимостей электропотребления от температуры воздуха и освещенности в операционной зоне Ростовского РДУ // Изв. вузов. Электромеханика. 2009. Спец. вып. С. 105-107.
2. Надтока И.И., Вялкова С.А., Корнюкова О.А. Сравнительный анализ методов одномерного и многомерного спектрального анализа при очистке от шумовой составляющей временного ряда электропотребления 2012-2013 годов // Электроэнергетика глазами молодежи: научные труды IV Междунар. науч.-техн. конф. Новочеркасск: ЮРГТУ, 2013. С. 194-197.
3. Губский С.О. Учет освещенности при краткосрочном прогнозировании электропотребления для региональных диспетчерских управлений: автореф. ... канд. техн. наук. Новочеркасск, 2012. 23 с
4. Влияние колебаний метеорологических факторов на энергопотребление энергообъединений / Б.И. Макоклюев, В.С. Павликов, А.И. Владимиров, Г.И. Фефелова // Энергетик. 2003. №6. С. 14-19.
5. Шумилова Г.П., Готтман Н.Э., Старцева Т.Б. Прогнозирование электрических нагрузок при оперативном управлении электроэнергетическими системами на основе нейросетевых структур. Екатеринбург: УрОРАН, 2008. 89с.
6. Грицай А.С. Гибридный метод краткосрочного прогнозирования потребления электрической энергии для энергосбытового предприятия с учетом метеофакторов: автореф. ... канд. техн. наук: 05.09.03. Омск, 2017. 22 с.
7. S. Vyalkova, I. Nadтока. Short-term forecasting using fuzzy neural network accountability air temperature and natural lighting, 2nd International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 19-20 May 2016, Chelyabinsk, Russia, 2016. [Online]. Available: <https://ieeexplore.ieee.org/document/7910991>.
8. Nadтока I., Vyalkova S. Hybrid Speculation Model of Energy Consumption Based on Multivariate Singular Spectrum Analysis and Neural Fuzzy Network, 2019 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 25-29 March 2019, IEEE, Sochi, Russia, 2019. [Online]. Available: <https://ieeexplore.ieee.org/ocumment/8742971>.
9. Сердюкова Г.Н. Прогнозирование электропотребления с использованием нейро-нечетких сетей. Харьковский политехн. ин-т, г. Харьков: 2008. С. 229-233.
10. Дерево принятия решений: [Online]. Available: <http://www.amse.ru/archive/courses/2006/nikolenko/notes-01-dectrees.pdf>.
11. Шахиди А. Деревья решений: общие принципы. 4 декабря 2019. [Online]. Available: <https://loginom.ru/blog/decision-tree-p1>.
12. Девяткин Д., Григорьев О. Метод обучения деревьев решений с нелинейными разделителями // Искусственный интеллект и принятие решений. 2022. Т. 3. С. 95—104.
13. Breiman L. (1984). Classification and Regression Trees (1st ed.). Routledge. [Online]. Available: [Online]. Available: <https://doi.org/10.1201/9781315139470>.
14. Random Forests Leo Breiman and Adele Cutler. [Online]. Available: https://www.stat.berkeley.edu/~breiman/RandomForests/cc_home.htm
15. Breiman L., Friedman J.H., Olshen R.A., Stone C.T. Classification and Regression Trees. Wadsworth, Belmont, California, 1984.
16. Documentation scikit-learn: machine learning in Python. [Online]. Available: <http://scikitlearn.org/stable/documentation.html>
17. Friedman Jerome H. Greedy Function Approximation: A Gradient Boosting Machine, IMS 1999 Reitz Lecture, 24 February 1999 (modified March 15, 2000, April 19, 2001), USA, 2001, [Online]. Available: <https://jerryfriedman.su.domains/ftp/trebst.pdf>.
18. Вялкова С.А. Краткосрочное прогнозирование электропотребления мегаполиса на основе ортогональных разложений и нейронных сетей: специальность: 05.14.02: автореф. ... канд. техн. наук. Новочеркасск, 2022. 24 с.

References

1. Nadтока I.I., Gubskij S.O. Analysis of the dependences for power consumption on air temperature and illumination in the operating area of the Rostov Regional Dispatch Office. *Journal Russian Electromechanics*; 2009;(Spec. release):105-107. (In Russ.)
2. Nadтока I.I., Vjalkova S.A., Kornjukova O.A. Comparative analysis of methods of one-dimensional and multivariate spectral analysis when cleaning from the noise component of the time series power consumption in 2012-2013. *Electric power industry through the eyes of youth: scientific works of the IV Intern. scientific and technical conf.* Novocherkassk: Platov South-Russian State Polytechnic University (NPI); 2013. Pp. 194-197.

3. Gubskij S.O. *Accounting for illumination in short-term forecasting of electricity consumption for regional dispatch offices*. Abstract Cand. Sci. Dis. (Eng.). Novocherkassk; 2012. 23 p.
4. Makokljuev B.I., Pavlikov V.S., Vladimirov A.I., Fefelova G.I. Influence of fluctuations of meteorological factors on the energy consumption of power grids. *Energetics*. 2003;(6):14-19.
5. Shumilova G.P., Gottman N.E., Startseva T.B. *Forecasting electrical loads in the operational management of electrical power systems based on neural network structures*. Ekaterinburg: UrORAN; 2008, 89 p.
6. Gritsai A.S. *Hybrid method of electrical energy consumption short-term forecasting for an energy sales enterprise taking into account meteorological factors: Ph.D. thesis: 05.09.03*. Omsk; 2017. 150 p.
7. Vyalkova S., Nadtoka I. Short-term forecasting using fuzzy neural network accountability air temperature and natural lighting. *2nd International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 19-20 May 2016, Chelyabinsk, Russia*. 2016. Available at: <https://ieeexplore.ieee.org/document/7910991>.
8. Nadtoka I., Vyalkova S. Hybrid Speculation Model of Energy Consumption Based on Multivariate Singular Spectrum Analysis and Neural Fuzzy Network, *2019 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 25-29 March 2019, IEEE, Sochi, Russia, 2019*. Available at: <https://ieeexplore.ieee.org/ocumet/8742971>.
9. Serdyukov G.N. *Forecasting power consumption using neuro-fuzzy networks*. Kharkov: Kharkov Polytechnic Institute; 2008. Pp. 229-233.10.
10. Akobir Shahidi. *Decision tree*. Available at: <http://www.amse.ru/archive/courses/2006/nikolenko/notes-01-dectrees.pdf11>.
11. *Decision Trees: General Principles*. December 4; 2019. Available at: <https://loginom.ru/blog/decision-tree-p112>.
12. Devyatkin D., Grigoriev O. Method of training decision trees with nonlinear separators. *Artificial intelligence and decision making*. 2022;(3):95-104.
13. Breiman L. *Classification and Regression Trees (1st ed.)*. Routledge. 1984. Available at: <https://doi.org/10.1201/9781315139470>.
14. *Random Forests* Leo Breiman and Adele Cutler. Available at: https://www.stat.berkeley.edu/~breiman/RandomForests/cc_home.htm
15. Breiman L., Friedman J.H., Olshen R.A. and Stone C.T. *Classification and Regression Trees*. Wadsworth, Belmont, California; 1984.
16. *Documentation scikit-learn: machine learning in Python*. Available at: <http://scikitlearn.org/stable/documentation.html>
17. Jerome H. Friedman. *Greedy Function Approximation: A Gradient Boosting Machine*. IMS 1999 Reitz Lecture, 24 February 1999 (modified March 15, 2000, April 19, 2001), USA, 2001. Available at: <https://jerryfriedman.su.domains/ftp/trebst.pdf>
18. Vyalkova S. A. *Short-term forecasting of a metropolis power consumption based on orthogonal decompositions and neural networks: specialty: 05.14.02*. Cand. Sci. Dis. (Eng.). Novocherkassk; 2022. 224 p.

Информация об авторах:

С.А. Вялкова – канд. техн. наук, доцент кафедры «Прикладная математика», Южно-Российский государственный политехнический университет (НПИ) имени М.И. Платова, mazaeva_sveta@mail.ru

О.А. Корнюкова – канд. техн. наук, доцент кафедры «Прикладная математика», Южно-Российский государственный политехнический университет (НПИ) имени М.И. Платова, korniyukova_o@mail.ru

И.И. Надтока – д-р техн. наук, профессор, Южно-Российский государственный политехнический университет (НПИ) имени М.И. Платова, ii_nadtoka@mail.ru

Information about the authors:

S.A. Vyalkova – Cand. Sci. (Eng.), Associate Professor, Department «Applied Mathematics», Platov South-Russian State Polytechnic University (NPI), mazaeva_sveta@mail.ru

O.A. Korniyukova – Cand. Sci. (Eng.), Associate Professor, Department «Applied Mathematics», Platov South-Russian State Polytechnic University (NPI), korniyukova_o@mail.ru

I.I. Nadtoka – Dr. Sci. (Eng.), Professor, Platov South-Russian State Polytechnic University (NPI), ii_nadtoka@mail.ru

Статья поступила в редакцию / the article was submitted 16.04.2025;

одобрена после рецензирования / approved after reviewing 18.07.2025;

принята к публикации / accepted for publication 22.07.2025.