

Л. Ю. Емалетдинова, А. Н. Кабирова, Н. Р. Вильданов

НЕЙРОСЕТЕВОЕ МОДЕЛИРОВАНИЕ ЗАДАЧИ ПРОГНОЗИРОВАНИЯ ЗНАЧЕНИЙ ВРЕМЕННОГО РЯДА

Ключевые слова: прогнозирование, временной ряд, сверточные нейронные сети, многослойный перцептрон.

Разработаны модели прогнозирования значений временного ряда на основе многослойного перцептрона и сверточной нейронной сети. Проведен сравнительный анализ результатов прогнозирования с помощью традиционной модели SARIMA и нейросетевых моделей. Временной ряд представляет данные о почасовом потреблении электроэнергии. Ряд характеризуется стохастической и сезонной компонентами, а также наличием нелинейной трендовой составляющей. Вывод о нестационарности временного ряда был сделан на основе теста Дики - Фуллера. Период сезонности определяется на основе анализа автокорреляционной функции временного ряда, а также на основе вычисления индексов сезонности. На основе временного ряда была построена выборка для обучения и тестирования нейросетевых моделей, содержащая 50000 кортежей данных. Анализ данных и построение моделей прогнозирования осуществлены с помощью авторского программного комплекса, реализованного на языке программирования Python. Исследовано влияние изменения параметров сверточного слоя и субдискретизирующего окна на точность прогнозирования. В качестве метрики для измерения точности значений прогнозирования выбрано среднеквадратическое отклонение прогнозных значений от реальных. Результаты исследований показали, что увеличение числа и размера ядер сверточного слоя приводит к повышению точности прогнозирования. Увеличение же размера субдискретизирующего окна повышает точность прогнозирования значений временного ряда незначительно. В целом нейросетевые модели показывают лучшие результаты по сравнению с традиционной моделью, при этом точность прогнозирования с помощью сверточной нейросетевой модели выше, чем у многослойного перцептрона.

L. U. Emaletdinova, A. N. Kabirova, N. R. Vildanov

NEURAL NETWORK MODELING OF THE TIME SERIES VALUES PREDICTION PROBLEM

Keywords: forecasting, time series, convolutional neural networks, multilayer perceptron.

The models for predicting time series values based on multilayer perceptron and convolutional neural network were developed. A comparative analysis of the results of forecasting using the traditional SARIMA model and neural network models was carried out. The time series represents data on hourly electricity consumption. The series is characterized by stochastic and seasonal components, as well as the presence of a non-linear trend component. The conclusion about the non-stationary of the time series was made on the basis of the Dickey-Fuller test. The seasonality period is determined based on the analysis of the autocorrelation function of the time series, as well as on the basis of the calculation of seasonality indices. Based on the time series, a sample was built for training and testing neural network models, containing 50000 data lines. Data analysis and forecasting models were built using a software package implemented in the Python programming language. The effect of changing the parameters of the convolutional layer and the subsampling window on the prediction accuracy was investigated. As a metric for measuring the accuracy of the forecast values the standard deviation of the forecast values from the real ones was chosen. The dependence of the change in the prediction accuracy on the size and number of convolution kernels, as well as dependence on the size of the subsampling window, are considered. The research results showed that an increase in the number and size of convolutional layer kernels lead to an increase in prediction accuracy. And increasing the size of the subsampling window increases the accuracy of predicting the values of the time series slightly. In general, neural network models show better results compared to the traditional model, while the prediction accuracy using a convolutional neural network model is higher than that of a multilayer perceptron.

Введение

При прогнозировании значений переменной, изменение состояния которой описывается временным рядом, в настоящее время применяются различные традиционные модели. При этом если описываемый процесс является стационарным, то для его анализа применяются авторегрессионная модель AR(p), модели скользящего среднего MA(q), а также авторегрессии — скользящего среднего ARMA(p,q), где p, q — параметры моделей. Так, например, в работе [1] данные модели применяются для прогнозирования цен на нефть, в работе [2] — для прогнозирования сетевого трафика. В случае если процесс является нестационарным, то для его анализа применяются интегрированная модель авторегрессии скользящего среднего ARIMA(p,d,q) и модель сезонной интегрированной авторегрессии

SARIMA(p, d, q) (P_s , D_s , Q_s), здесь d- порядок разности временного ряда, P_s - параметр авторегрессионной сезонной составляющей, Q_s - параметр сезонной составляющей скользящего среднего, D_s - порядок разности сезонной составляющей, s - размерность сезонности (квартал, месяц и т.д.). В работе [3] данные модели применяются для прогнозирования спроса на товары, в работе [4] для прогнозирования демографических данных, таких как численность населения, уровень рождаемости и смертности и т.д., в [5] — для анализа и прогнозирования распространения загрязняющих веществ в воздухе, в [6] — для прогнозирования пропускной способности морского порта.

Несмотря на то, что традиционные модели применяются для прогнозирования во многих

областях, все они строятся как аппроксимация временного ряда линейной зависимостью текущего значения выходной переменной от некоторого количества ее предыдущих значений. Однако линейность данной зависимости является недостатком модели, и может привести к значительным ошибкам при прогнозировании.

Развитие технологий интеллектуального анализа на основе нейросетевых моделей позволяет аппроксимировать временной ряд нелинейной зависимостью. При решении задач прогнозирования применяются различные виды искусственных нейронных сетей, наиболее распространенными из которых являются сети прямого распространения и сверточные нейронные сети. Так, например, в работе [7] для прогнозирования динамики развития заболеваний применяется трехслойная рекуррентная сеть прямого распространения, в работе [8] нейронная сеть применяется для прогнозирования поведения параметров фотоэлектрической системы, а в работе [9] для прогнозирования колебаний грунта при буровзрывных работах. В работе [10] применяют сверточную нейронную сеть для прогнозирования цен на электроэнергию, а в [11] при прогнозировании речного стока для водохранилища.

Особенности применения нейросетевых моделей в задачах прогнозирования

При создании искусственной нейронной сети необходимо подобрать ее архитектуру, сформировать выборки для обучения и тестирования, на основе которых определить значения параметров сети. В работе [12] рассматривается метод построения прогнозной модели в виде многослойного персептрона. Одним из ключевых моментов при построении нейросетевых моделей, влияющего на ее адекватность, является определение состава входных переменных. Для задачи определения состава входных переменных прогнозной нейросетевой модели временного ряда предлагается метод, базирующийся на использовании особенностей поведения автокорреляционной и частной автокорреляционной функций.

Сверточные нейронные сети получили свое название из-за содержания сверточных слоев, чередующихся с субдискретизирующими слоями (окнами). После этих слоев, в качестве заключительного слоя, сеть включает в себя многослойный персептрон [13]. На рисунке 1 приведена схема сверточной нейронной сети, содержащей два сверточных и два субдискретизирующих слоя.




Рис. 1 - Схема сверточной нейронной сети
Fig. 1 – Scheme of the convolutional neural network

Сверточные слои предназначены для обработки входных данных или результатов предыдущего слоя при помощи фильтра – ядра свертки. Субдискретизирующий слой используется для уменьшения размера входящих в него данных. Данные, которые являются результатами обработки этих чередующихся слоев, поступают на вход многослойного персептрона. То есть, после обработки исходных данных сверточными и субдискретизирующими слоями, на вход персептрона поступают выделенные этими слоями признаки. Данная особенность принципа функционирования сверточных нейронных сетей дает возможность эффективно обнаруживать ключевые признаки из множества входных данных. При этом при разработке сверточных нейронных сетей возникает необходимость варьирования большого числа различных параметров, обеспечивающих требуемую точность получаемых прогнозных значений. К таким параметрам относятся: число сверточных и субдискретизирующих слоев, число и размер ядер свертки, размер субдискретизирующих окон.

Анализ временного ряда

Объектом для анализа был выбран набор данных о почасовом потреблении электроэнергии в разных регионах США по открыто опубликованным данным компании PJM Interconnection LLC с 1 января 2018 года по 31 декабря 2021 года. Набор содержит более 50 тыс. строк данных (рис.2).




Рис. 2 – Фрагмент диаграммы исследуемых данных

Fig. 2 – Fragment of the diagram of the studied data

Исходя из диаграммы исследуемых значений, было сделано предположение о возможном нестационарном характере данных. Проверка данного факта осуществлялась при помощи теста Дики-Фуллера, который применяется при анализе временных рядов для проверки стационарности ряда.

В результате проведения теста получено значение статистики Дики – Фуллера, равное -1,61. Данное значение превышает критическое значение статистики -2,87 при 5% уровне значимости. Таким образом, рассматриваемый временной ряд является нестационарным.

С целью определения содержания в данных сезонной составляющей была построена и

проанализирована автокорреляционная функция (АКФ) (рис. 3).




Рис. 3 – Автокорреляционная функция исследуемых данных

Fig. 3 – Autocorrelation function of the studied data

Анализ автокорреляционной функции, вид которой имеет периодический характер, позволил сделать вывод о наличии в рассматриваемых данных сезонной составляющей, с периодом «сезонности» 24 часа, то есть величина энергопотребления имеет подневные циклы.

Для более точной проверки определения периода сезонности были рассчитаны индексы сезонности для каждого часа в сутках. При этом индекс сезонности u_t рассчитывается на основе исходного временного ряда как:

$$u_t = \frac{Y_{st}}{Y_{s0}},$$

где $Y_{st} = \frac{\sum_{i=1}^k Y_{it}}{k}$ – средняя по каждому внутрисезонному периоду t (например, часу) для всех k сезонов (например, суток);

$$Y_{s0} = \frac{\sum_{i=1}^k \sum_{t=1}^p Y_{it}}{kp}$$

- общая средняя по всем

сезонам (k) и внутрисезонным периодам (p),

Y_{it} – значение временного ряда для внутрисезонного периода t (например, часа) и для текущего сезона i (например, сутки).

Результаты вычислений приведены в таблице 1.

Анализ полученных результатов подтверждает, что период сезонности равен 24 часа.

Для прогнозирования было принято решение проанализировать три различных модели: традиционную модель SARIMA, многослойную нейронную сеть – перцептрон (MLP) и сверточную нейронную сеть. Модели строятся исходя из того, что рассматриваемый временной ряд является нестационарным.

Для проведения анализа временного ряда и построения моделей прогнозирования был разработан программный комплекс, реализованный на языке программирования Python. Для математической обработки данных были использованы библиотеки numpy и statsmodels, а для построения моделей – sklearn, keras и tensorflow.

Таблица 1 – Изменение индексов сезонности в течение суток

Table 1 – Variation of seasonality indices during the day

Время (час/мин)	Индекс сезонности	Время (час/мин)	Индекс сезонности
00:00	1.072	12:00	1.022
01:00	1.050	13:00	1.039
02:00	1.006	14:00	1.048
03:00	0.955	15:00	1.054
04:00	0.912	16:00	1.058
05:00	0.884	17:00	1.062
06:00	0.869	18:00	1.062
07:00	0.864	19:00	1.059
08:00	0.870	20:00	1.060
09:00	0.894	21:00	1.066
10:00	0.940	22:00	1.075
11:00	0.988	23:00	1.078

Для определения параметров p , d , q , P_s , D_s , Q_s традиционной модели SARIMA используем методику анализа автокорреляционной (АКФ) и частной автокорреляционной (ЧАКФ) функций стационарного временного ряда [14]. Данная методика заключается в следующем:

1. Если временной ряд стационарный и трендовая и сезонная составляющие отсутствуют, тогда параметры p , q определяются по ЧАКФ и АКФ соответственно и равны числу лагов, для которых коэффициент корреляции наиболее значимый.

2. Если временной ряд нестационарный, присутствует тренд, но сезонности нет, тогда ряд преобразовывается методом взятия конечных разностей. Считается, что порядок разности d определен, если при взятии разности порядка d исходный нестационарный ряд становится стационарным. Параметры p и q определяются на основе АКФ и ЧАКФ преобразованного стационарного ряда.

3. Если временной ряд нестационарный, присутствуют и тренд, и сезонность, то ряд преобразовывается к стационарному виду методом конечных разностей не только для текущих значений временного ряда, но и для его сезонных составляющих. Порядок разности d и порядок разности сезонной составляющей D_s считаются определенными, если при взятии разности порядка D , а затем порядка d , исходный нестационарный ряд становится стационарным. При этом первые P_s лагов в ЧАКФ преобразованного ряда, отличные от нуля и повторяющиеся через период s , определяют порядок сезонной составляющей авторегрессии. Первые Q_s лагов в АКФ ряда, отличные от нуля и повторяющиеся через период s , определяют порядок сезонной составляющей скользящего среднего.

Так как наш временной ряд является нестационарным, содержит тренд и сезонную составляющую, то для определения параметров по изложенной методике преобразовываем его к

стационарному виду путем взятия конечных разностей не только для текущих значений временного ряда, но и для его сезонных составляющих.

Анализ результатов прогнозирования значений временного ряда традиционной моделью SARIMA и нейросетевыми моделями

В результате проведения экспериментальных исследований были построены следующие модели:

1) SARIMA(2, 1, 4)(4, 1, 2, 24), для которой среднеквадратичное отклонение прогнозируемых значений от действительных составило 0,11.

2) Многослойный перцептрон с одним скрытым слоем и 47 нейронами в слое. На вход сети поступает вектор с 24 элементами в связи с периодичностью данных во временном ряде в 24 часа. Выход содержит одно прогнозируемое значение. Среднеквадратичное отклонение прогнозируемых значений от действительных составило 0,086.

3) Сверточная нейронная сеть, содержащая один сверточный слой с 64 фильтрами размера 3 и один субдискретизирующий слой с размером окна 2. На вход сеть получает вектор с 24 элементами. Результат подается на многослойный перцептрон с одним скрытым слоем, содержащим 10 нейронов и одним выходом. Среднеквадратичное отклонение прогнозируемых значений от действительных составило 0,074.

Таким образом, нейросетевые модели прогнозирования показали лучшие результаты по сравнению с традиционной моделью. Среди нейросетевых моделей наилучший результат показала модель, основанная на сверточной нейронной сети. Однако было сделано предположение, что существует возможность улучшения результатов прогнозирования за счет изменения параметров сети.

Исследование влияния размера и числа ядер сверточного слоя и размера субдискретизирующего окна сверточной нейронной сети на точность прогнозирования

Рассмотрим влияние изменения параметров сверточной нейронной сети на качество прогнозирования значений временного ряда.

С целью сокращения временных затрат на обучение и тестирования нейронных сетей, временной ряд для тестирования был сгенерирован искусственно. Полученный в результате ряд характеризуется сочетанием стохастической компоненты, нелинейной трендовой составляющей и сезонной компоненты. Сезонная периодичность ряда равна 20. Объем сгенерированного временного ряда составил 50000 строк данных, из которых 70% сгенерированной выборки используется для обучения нейронных сетей, а 30% - для тестирования.

В качестве метрики для измерения точности прогнозных значений было выбрано среднеквадратическое отклонение.

Рассматриваемая модель сверточной нейронной сети получает на вход вектор с 20 элементами, и имеет одну выходную переменную. Структура сети содержит один сверточный слой, один субдискретизирующий слой. Результат работы данных слоев передается многослойному перцептрон с одним скрытым слоем, содержащим 10 нейронов и одним выходным нейроном.

Рассмотрим влияние изменения числа и размера ядер-фильтров сверточного слоя на качество прогнозирования (табл.2). При этом размер субдискретизирующего окна выбран равным 2.

Таблица 2 – Зависимость точности прогнозирования от размера и числа ядер сверточного слоя

Table 2 – Dependence of prediction accuracy on the size and number of convolutional layer kernels

Размер ядер \ Число ядер	3	5	7	9	11
20	0.0122	0.0113	0.01064	0.0096	0.0084
40	0.0120	0.0110	0.01016	0.0092	0.0083
60	0.0119	0.0110	0.01036	0.0089	0.0079
80	0.0119	0.0112	0.01009	0.0093	0.00786
100	0.0120	0.0110	0.01039	0.0089	0.00784

Также на основе полученных данных были построены диаграммы, иллюстрирующие изменение погрешности при изменении параметров сверточного слоя (рис. 4, 5).




Рис. 4 – Диаграмма изменения точности в зависимости от размера ядер сверточного слоя

Fig. 4 – Diagram of the change in accuracy depending on the size of the convolutional layer kernels

Из табл. 2 и рис. 4,5 видно, что увеличение числа ядер на точность прогнозируемых значений значительного влияния не оказывает, однако увеличение размера ядер приводит к улучшению значений метрик. Однако необходимо учесть, что задание числа и размера ядер свертки связано с объемом обучающей выборки, поэтому при построении сверточной нейросетевой модели целесообразно начинать с малых значений данных параметров, а затем увеличивать их, добиваясь

достижения заданной точности прогнозных значений.




Рис. 5 – Диаграмма изменения точности в зависимости от числа ядер сверточного слоя

Fig. 5 – Diagram of the accuracy change depending on the number of convolutional layer kernels

В табл. 3 приведены результаты экспериментальных исследований, демонстрирующие зависимость точности прогнозирования от размера субдискретизирующего слоя. При этом число ядер и их размер были фиксированными и равными соответственно 100 и 11.

Таблица 3 – Зависимость точности прогнозирования от размера субдискретизирующего слоя

Table 3 – Dependence of prediction accuracy on the size of the subsampling layer

Размер субдискретизирующего окна	Значение метрик
2	0.00784
3	0.00731
4	0.00754
5	0.00639
6	0.00676

Результаты эксперимента показывают, что увеличение размера субдискретизирующего слоя повышает точность прогнозирования значений временного ряда незначительно.

Закключение

Проведен сравнительный анализ применения традиционной и нейросетевых моделей в задачах прогнозирования значений нестационарного временного ряда с трендовой и сезонной составляющими. Установлено, что нейросетевые модели, а именно многослойный перцептрон и сверточная нейронная сеть, обеспечивают большую точность прогнозирования, чем традиционная модель. Входы нейросетевых моделей сформированы согласно периодичности данных во временном ряду. При этом точность прогнозирования сверточной нейронной сетью превышает точности перцептрона. Исследовано влияние изменения параметров сверточной нейронной сети на результаты прогнозирования.

Результаты исследования показали, что увеличение числа и размера ядер сверточного слоя приводят к повышению точности прогнозирования, а увеличение размера субдискретизирующего слоя повышает точность прогнозирования значений временного ряда незначительно.

Литература

1. Ю.Б. Гурвиц. Моделирование и прогнозирование цен на нефть / Ю. Б. Гурвиц // Актуальные проблемы гуманитарных и естественных наук. – 2013. – № 1. – С. 94-98.
2. К. М. Лапкин, Е. В. Данилова. Анализ краткосрочных моделей для прогнозирования сетевого трафика // Современные тенденции и проекты развития информационных систем и технологий: материалы Межрегиональной научно-исследовательской конференции студентов и школьников, Хабаровск, 26 мая 2021 года / под науч. ред. канд. техн. наук О. И. Чуйко. – Хабаровск: РИЦ ХГУЭП, 2021. – С. 48-53.
3. К.О. Привалов. Прогнозирование спроса на товары с использованием моделей arima и sarima / К.О. Привалов // Развитие научно-технического творчества детей и молодежи - НТТДМ 2021: Сборник материалов V Всероссийской научно-практической конференции с международным участием, Смоленск, 21 мая 2021 года. – Киров: Межрегиональный центр инновационных технологий в образовании, 2021. – С. 107-113.
4. Е.Д. Копнова, Л.А. Родионова. Статистические подходы к анализу и прогнозированию демографических данных // Известия Саратовского университета. Новая серия. Серия: Экономика. Управление. Право. – 2016. – Т. 16. – № 3. – С. 306-315.
5. T. Kumar, H.S. Das, U. Choudhary, P.E. Dutta, D. Guha, Y. Laskar. Analysis and Prediction of Air Pollution in Assam Using ARIMA/SARIMA and Machine Learning. In: Muthukumar, P., Sarkar, D.K., De, D., De, C.K. (eds) Innovations in Sustainable Energy and Technology. Advances in Sustainability Science and Technology. Springer, Singapore.
6. K. Mokhtar, S.M. Mhd Ruslan, A. Abu Bakar, J. Jeevan, M.R. Othman. The Analysis of Container Terminal Throughput Using ARIMA and SARIMA. In: Ismail, A., Dahalan, W.M., Öchsner, A. (eds) Design in Maritime Engineering. Advanced Structured Materials, vol 167. Springer, Cham.
7. А.Г. Хасанов, Д.Г. Шайбаков, С.В. Жернаков, А.М. Меньшиков, Ф.Ф. Бадретдинова, И.Ф. Суфияров, Ю.Р. Сагадатов. Нейронные сети для прогнозирования динамики развития заболеваний// Креативная хирургия и онкология. – 2020. – Т. 10. – № 3. – С. 198-204.
8. L. Miloudi, D. Acheli, M. Kesraoui. Application of artificial neural networks for forecasting photovoltaic system parameters. Appl. Sol. Energy 53, 85–91 (2017).
9. K. Taheri, M. Hasanipanah, S.B. Golzar, M.Z. Majid. A hybrid artificial bee colony algorithm-artificial neural network for forecasting the blast-produced ground vibration. Engineering with Computers 33, 689–700 (2017).
10. Z.A. Khan, S. Fareed, M. Anwar, A. Naeem, H. Gul, A. Arif, N. Javaid. Short Term Electricity Price Forecasting Through Convolutional Neural Network (CNN). In: Barolli, L., Amato, F., Moscato, F., Enokido, T., Takizawa, M. (eds) Web, Artificial Intelligence and Network Applications. WAINA 2020. Advances in Intelligent Systems and Computing, vol 1150. Springer, Cham.
11. X. Shu, W. Ding, Y. Peng, Z. Wang, J. Wu, M. Li. Monthly Streamflow Forecasting Using Convolutional Neural Network. Water Resour Manage 35, 5089–5104 (2021).

12. Л.Ю. Емалетдинова, З.И. Мухаметзянов, Д.В. Катасёва, А.Н. Кабиров. Метод построения прогнозной нейросетевой модели временного ряда // Компьютерные исследования и моделирование. 2020. Т. 12. № 4. С. 737-756.
13. Ч. Аггарвал. Нейронные сети и глубокое обучение: учебный курс.: Пер. с англ. – СПб.: ООО «Диалектика», 2020. – 752 с.
14. А.В. Трегуб, И.В. Трегуб. Методика построения модели ARIMA для прогнозирования динамики временных рядов // Лесной вестник. – 2011. – № 5 (81). – С.179-183.

References

1. Y.B. Gurvits. Modeling and Forecasting Oil Prices / Yu.B. Gurvits // Actual Problems of Humanities and Natural Sciences. - 2013. - № 1. - P. 94-98.
2. K. M. Lapkin, E. V. Danilova. Analysis of short-term models for network traffic forecasting // Modern trends and projects of information systems and technologies development: materials of the Interregional Research Conference of Students and Schoolchildren, Khabarovsk, May 26, 2021 / edited by Candidate of Technical Sciences O. I. Chuiko. - Khabarovsk: RIC KSUEP, 2021. - P. 48-53.
3. K.O. Privalov. Forecasting Demand for Goods Using Arima and Sarima Models / K.O. Privalov // Development of Scientific and Technical Creativity of Children and Youth - NTTDM 2021: Proceedings of the V All-Russian Scientific Conference with International Participation, Smolensk, May 21, 2021. - Kirov: Interregional Center for Innovative Technologies in Education, 2021. - P. 107-113.
4. E. D. Kopnova, L. A. Rodionova. Statistical Approaches to the Analysis and Forecasting of Demographic Data // Izvestiya Saratovskogo Universiteta. New Series. Series: Economics. Management. Law. - 2016. - V. 16. - № 3. - P. 306-315.
5. T. Kumar, H.S. Das, U. Choudhary, P.E. Dutta, D. Guha, Y. Laskar. Analysis and Prediction of Air Pollution in Assam Using ARIMA/SARIMA and Machine Learning. In: Muthukumar, P., Sarkar, D.K., De, D., De, C.K.. (eds) Innovations in Sustainable Energy and Technology. Advances in Sustainability Science and Technology. Springer, Singapore.
6. K. Mokhtar, S.M. Mhd Ruslan, A. Abu Bakar, J. Jeevan, M.R.. Othman. The Analysis of Container Terminal Throughput Using ARIMA and SARIMA. In: Ismail, A., Dahalan, W.M., Öchsner, A. (eds) Design in Maritime Engineering. Advanced Structured Materials, V. 167. Springer, Cham.
7. A.G. Khasanov, D.G. Shaibakov, S.V. Zhernakov, A.M. Menshikov, F.F. Badretdinova, I.F. Sufiyarov, Y.R. Sagadatova. Neural networks for disease dynamics prediction// Creative Surgery and Oncology. - 2020. - V. 10. - № 3. - P. 198-204.
8. L. Miloudi, D. Acheli, M. Kesraoui. Application of artificial neural networks for forecasting photovoltaic system parameters. Appl. Sol. Energy 53, 85-91 (2017).
9. K. Taheri, M. Hasanipanah, S.B. Golzar, M.Z. Majid. A hybrid artificial bee colony algorithm-artificial neural network for forecasting the blast-produced ground vibration. Engineering with Computers 33, 689-700 (2017).
10. Z.A. Khan, S. Fareed, M. Anwar, A. Naeem, H. Gul, A. Arif, N. Javaid. Short Term Electricity Price Forecasting Through Convolutional Neural Network (CNN). In: Barolli, L., Amato, F., Moscato, F., Enokido, T., Takizawa, M. (eds) Web, Artificial Intelligence and Network Applications. WAINA 2020. Advances in Intelligent Systems and Computing, vol 1150. Springer, Cham.
11. X. Shu, W. Ding, Y. Peng, Z. Wang, J. Wu, M. Li. Monthly Streamflow Forecasting Using Convolutional Neural Network. Water Resour Manage 35, 5089-5104 (2021).
12. L.Y. Emaletdinova, Z.I. Mukhametzyanov, D.V. Kataseva, A.N. Kabirova. A method for building a predictive neural network model of time series // Computer Research and Modeling. 2020. V. 12. № 4. P. 737-756.
13. Ch. Aggarwal. Neural Networks and Deep Learning: A Training Course. - 752 p.
14. A.V. Tregub, I.V. Tregub. Methods of ARIMA Model Construction for Forecasting the Dynamics of Time Series // Lesnoy Vestnik. - 2011. - № 5 (81). - P.179-183.

© **Л. Ю. Емалетдинова** – профессор, профессор кафедры прикладной математики и информатики, Казанский национальный исследовательский технический университет им. А.Н. Туполева, e-mail: lilia@stcline.ru; **А. Н. Кабиров** – доцент, доцент кафедры прикладной математики и информатики, Казанский национальный исследовательский технический университет им. А.Н. Туполева, e-mail: kabirovaigul@mail.ru; **Н. Р. Вильданов** – аспирант кафедры прикладной математики и информатики, Казанский национальный исследовательский технический университет им. А.Н. Туполева e-mail: vildanov.n98@gmail.com.

© **L. U. Emaletdinova** – Professor of the Applied Mathematics and Informatics (AMI) department, Kazan National Research Technical University named after A.N. Tupolev, e-mail: lilia@stcline.ru; **A. N. Kabirova** – Docent of the AMI department, Kazan National Research Technical University named after A.N. Tupolev, e-mail: kabirovaigul@mail.ru; **N. R. Vildanov** – PhD-student of the AMI department, Kazan National Research Technical University named after A.N. Tupolev e-mail: vildanov.n98@gmail.com.

Все статьи номера поступили в редакцию журнала в период с 15.09.22 по 10.10.22.