

**ИНФОРМАЦИОННЫЕ И ИНТЕЛЛЕКТУАЛЬНЫЕ ТЕХНОЛОГИИ
В ТЕХНИКЕ И ОБРАЗОВАНИИ**

УДК 004

ОБЗОР МЕТОДОВ ВЫЯВЛЕНИЯ АНОМАЛИЙ ВО ВРЕМЕННЫХ РЯДАХ**Л.Ю. Емалетдинова¹, Н.Р. Вильданов², А.Н. Кабирова³***Казанский национальный исследовательский технический университет им. А.Н. Туполева, Россия, Казань,**¹lilia@stcline.ru, ²vildanov.n98@gmail.com, ³kabirovaigul@mail.ru**Аннотация.* Проведен обзор существующих методов обнаружения аномалий во временных рядах. Проанализированы их достоинства и недостатки.*Ключевые слова:* аномалия, временной ряд, метод выявления аномалий, кластеризация, прогнозирование, нейросетевой метод.**OVERVIEW OF METHODS FOR DETECTING ANOMALIES IN TIME SERIES****L.Yu. Emaletdinova¹, N.R. Vildanov², A.N. Kabirova³***Kazan National Research Technical University named after A.N. Tupolev, Russia, Kazan,**¹lilia@stcline.ru, ²vildanov.n98@gmail.com, ³kabirovaigul@mail.ru**Abstract.* The article provides a review of existing methods for detecting anomalies in time series. Their advantages and disadvantages are analyzed.*Keywords:* anomaly, time series, anomaly detection method, clustering, forecasting, neural network method.

Для цитирования: Емалетдинова Л.Ю., Вильданов Н.Р., Кабирова А.Н. Обзор методов выявления аномалий во временных рядах // Математические методы в технологиях и технике. 2024. № 9. С. 47-51.

Введение. Проведение экспериментальных исследований и изучение свойств сложных систем в большинстве случаев сопровождается анализом временных рядов. Это особенно актуально, когда отсутствует возможность математически описать исследуемый процесс, однако имеется возможность снять значения одной или нескольких переменных через определенные промежутки времени. Последовательность таких значений определяется как временной ряд. Например, потребление электроэнергии, колебания земной коры, метеонаблюдения, число заболевших в сутки могут быть описаны временными рядами.

Часто временные ряды содержат аномалии. Под аномалией временного ряда понимается отклонение значений поведения исследуемого процесса от среднего поведения. Причинами возникновения аномалий могут являться непреднамеренные ошибки при регистрации значений или влияние внешних факторов. Наиболее часто встречающимися видами аномалий являются:

- точечные – это отдельные значения, которые резко отличаются от остальных значений исследуемого процесса;
- групповые – где аномальна группа значений, однако при этом отдельные значения этой группы не являются аномальными.

В настоящее время для выявления аномалий во временных рядах используются различные методы.

Для решения задачи обнаружения и классификации аномалий в заданных временных рядах в работах [1–3] авторы используют метод кластерного анализа. В работе [1] в качестве исходных данных используется набор данных с датчика программно-аппаратного комплекса автоматизированного контроля состава сточных вод. Отрезки временных рядов данных без аномалий группируются в кластеры, вычисляются центроиды кластеров, которые в дальнейшем используются для

выявления аномальных значений. При этом расстояние между значениями временного ряда до ближайшего кластерного центра является показателем наличия или отсутствия аномалии. Авторы [1] провели эксперименты с использованием алгоритма k-means. Результаты данного подхода показали нахождение большинства аномалий, но не всех. В связи с этим они рассмотрели другой подход на основе k-NN классификатора, который позволил найти больше аномалий во временном ряде. Этот классификатор предназначен для классификации непомеченных наблюдений и отнесения их к классу наиболее близких к помеченным. Классификатор k-NN для принятия решения использует евклидово расстояние: $\rho(x, x') = \sum_{i=1}^n (x_i - x'_i)^2$. Однако следует отметить, что евклидово расстояние эффективно использовать для временных рядов с небольшим числом измерений.

В работе [2] в качестве временного ряда выбирается ряд, содержащий информацию о транзакциях по банковским картам. Суть метода заключается в разбиении анализируемой совокупности точек на сравнительно небольшое число кластеров таким образом, чтобы объекты одного кластера находились на небольшом расстоянии. При этом в результате кластеризации объекты объединяются в группы разного размера. Кластеры, состоящие из одного объекта, являются претендентами для проверки на аномальность. В качестве меры сходства между объектами авторы применяют также евклидово расстояние. Для кластеризации выбран метод выделения связных компонент, согласно которому выборка представляется в виде графа. При этом вершинами графа являются объекты выборки, а ребрами расстояния $\rho(x, x')$ между ними. На вход алгоритма подается пороговое значение R и, если $\rho(x, x') > R$, то такие ребра удаляются из графа. При правильно заданном пороговом значении, граф разделится на несколько компонент связности, каждая из которых будет отдельным кластером. Изменяя пороговое значение, можно регулировать количество кластеров и аномалий. Необходимость подбора порогового значения можно отнести к недостаткам подхода.

В работе [3] предложен метод поиска аномалий на основе ансамблей алгоритмов DBSCAN, использующих внутреннюю структуру временных рядов. Метод DBSCAN – является часто используемым в кластеризации, и основан на плотности расположения точек. Если в некотором пространстве имеется набор точек, алгоритм группирует вместе тесно расположенные точки и отмечает, как выбросы точки, которые одиноко располагаются в областях с малой плотностью. Авторы отмечают сложность подбора оптимальных параметров метода и предлагают метод построения ансамблей DBSCAN на основе адаптивного подбора параметров, использующий особенность одномерных рядов.

В работе [4] рассмотрены расчетные методы обнаружения аномалий во временных рядах, в основе которых содержится проверка статистических гипотез, а также определенные визуальные методы. При этом визуальные методы дают только рекомендации по определению аномалий и их применяют для того, чтобы уменьшить количество значений ряда, проверяемых на аномальность. Применимость методов проверки статистических гипотез с использованием различных критериев для выявления аномалий проверено на основе 42-х временных рядов, взятых с сайта государственной статистики. В результате этого установлено, что наиболее хорошие показатели выявления аномалий у следующих методов: критерий межквартильного расстояния; критерий наибольшего абсолютного отклонения, критерий Романовского, критерий 3-х сигм, критерий Шовене, критерий Хоглина–Иглевича, критерий Роснера. Остальные методы показали неудовлетворительные результаты. Метод выявления аномального значения временного ряда на основе критерия 3-х сигм является наиболее часто используемым. Согласно этому критерию, если абсолютная величина

отклонения значения временного ряда от среднего значения превышает три среднеквадратических отклонения, то оно является аномальным: $|x_c - \bar{x}| \geq 3S$, где x_c – значение временного ряда; $\bar{x}$ – среднее значение временного ряда; S – среднеквадратическое отклонение.

В работе [5] также анализируются различные алгоритмы выявления аномалий, выделяются их достоинства и недостатки. Рассмотрим их более подробно.

Алгоритмы на основе скользящих окон. Временной ряд, используемый для обучения, разбивается на подпоследовательности (окна) длины m с шагом меньше длины окна (рис. 1). Чаще используется единичный шаг. В таком случае общее число окон может быть вычислено как $|S_i| - (m - 1)$, где $|S_i|$ – длина временного ряда.

Для поиска аномалий во временном ряду к окнам, полученным в результате его разбиения, могут применяться методы с учителем или без него.

В случае применения методов с учителем обнаружение аномалий временного ряда осуществляется на основе его сходства с окнами обучения, определяемыми с использованием функции подобия. В качестве функции подобия может применяться расстояние, корреляция и др. При применении метода скользящих окон без учителя оценка производится только между окнами анализируемого временного ряда, что может повлиять на итоговый результат.

Метрические алгоритмы. Эти алгоритмы сравнивают временной ряд, в котором обнаруживаются аномалии, с обучающими временными рядами, оценивая их близость на основе соответствующих метрик расстояния или подобия (рис. 2). В основе метода содержится предположение, что временные ряды, не содержащие аномалии, будут “близки”, а аномальные ряды – “далеки” от них в рамках выбранной метрики.




Рис. 1. Пример выделения окна с m равным 200




Рис. 2. Схематичное изображение оценки расстояния между временными рядами

Использование простых метрик, таких как евклидово расстояние, несмотря на преимущество в вычислительной скорости, требует использования временных рядов одинаковой длины. Сравнение временных рядов разной длины требует применения специальных методов, таких как, например, алгоритм динамической трансформации временной шкалы (DTW-алгоритм).

Алгоритмы на основе скрытых Марковских моделей. В основе алгоритмов лежит предположение о том, что значения временного ряда порождаются некоторым марковским процессом. Марковский процесс – это случайный процесс, в котором значения в момент времени t зависят только от значения в предшествующий ему момент $t-1$ и не зависят от значений в более ранние моменты. Математически марковский процесс может быть записан следующим образом: $X_t = c + \alpha X_{t-1} + \varepsilon_t$, где X_t – значение величины, описываемой марковским процессом в момент времени t ; X_{t-1} – значение величины, описываемой марковским процессом в момент времени $t-1$; c – константа; α – параметр авторегрессии; ε_t – белый шум.

Поиск параметров c и α марковского процесса осуществляется с использованием алгоритма Баума-Велша на основе временного ряда без аномалий, называемого

обучающим. После этого для оценки аномальности временного ряда вычисляется вероятность порождения такого временного ряда марковским процессом с полученными параметрами.

Алгоритмы на основе прогнозирования. В основе данной группы методов лежит предположение о том, что временные ряды, не содержащие аномалий, генерируются определенным процессом, в то время как возникающие аномалии не соответствуют этому процессу. Таким образом, если построить модель, предсказывающую значения временного ряда, после чего оценить разницу между прогнозным и фактическим значением, можно сделать вывод о наличии или отсутствии аномалии (рис. 3). Для этого на основе m предыдущих значений прогнозируется следующее значение временного ряда. В рамках данной задачи могут применяться различные математические модели, такие как модель скользящего среднего, авторегрессионная модель и их модификации, фильтры Калмана, линейная регрессия, регрессия Гауссовского процесса, метод опорных векторов и др.

Авторы работы [6] используют для выявления аномалий во временных рядах метод прогнозирования с обучением. Исследования проводятся на основе двухсот пятидесяти одномерных независимых временных рядов, которые разбиваются на обучающие и тестовые временные ряды. Временные ряды обучающей части не содержат аномалий для того, чтобы прогнозная модель не подстраивалась под них. Аномальные значения находятся только в тестовой части рассматриваемых данных.




Рис. 3. Разница между прогнозным (пунктирная линия) и фактическим (сплошная линия) значениями свидетельствует об аномалии

Реализация этого метода прогнозирования осуществлялось на основе:

- полносвязной нейронной сети;
- двунаправленной сети с долгой краткосрочной памятью (Bi-LSTM) – модификации рекуррентных нейронных сетей, способных учитывать долговременные зависимости;
- управляемых рекуррентных нейронов (Bi-GRU) – упрощенной версии LSTM сетей;
- градиентного бустинга (XGBoost) – техники машинного обучения, строящей модель прогнозирования в виде совокупности слабых предсказывающих моделей;
- градиентного бустинга LightGBM – более эффективной, быстрой и экономной реализации градиентного бустинга.

Для корректного решения задачи выявления аномалий временного ряда недостаточно лишь реализации модели прогнозирования, требуется и понимание того, какие именно значения считать аномальными. Для этого авторы [6] предлагают использовать интегральное отклонение, т.е. сумму отклонений на отдельно взятом участке. Результаты исследования показали эффективность применения Bi-LSTM модели.

Для обнаружения аномалий на основе метода прогнозирования можно также использовать нейронную сеть TCN [7, 8] и комбинационную нейронную сеть TCN-LSTM, предложенную в работе [9].

Модель TCN (Temporal Convolutional Network) представляет модель типа кодировщик-декодировщик, построенную на основе сверточной нейронной сети. При этом используются только сверточные слои без использования субдискретизирующих слоев. В сверточных слоях операция свертки заменена на каузальную свертку. Ее особенностью является то, что каждый элемент $x'(t)$ вектора результирующих значений сверточного слоя зависит от его входных значений $x(t), x(t-d), \dots$,

$x(t - d \times (q - 1))$). Временные моменты выбираются с заданным шагом d , называемым параметром расширения. Результат работы сверточного слоя модели TCN определяется как: $x'(t) = \sum_{i=0}^{q-1} w_i x(t - d \times i)$, где величины w_i определяют ядро свёрточного слоя. Используемая каузальная свертка приводит к тому, что размер вектора, получаемого в результате работы сверточного слоя модели TCN, будет равен размеру вектора входных данных слоя.

В работе [9] предложена комбинационная модель TCN-LSTM как модификация модели TCN с использованием сети LSTM. В архитектуре этой модели результатом работы кодировщика сети TCN являются временные признаки, полученные в результате операции каузальной свертки, которые имеют зависимость от времени t . Таким образом, результат работы кодировщика представляет новый временной ряд признаков исходного временного ряда. Из-за этого предложено прогнозировать значения признаков исходного временного ряда с использованием модели LSTM, которая учитывает долгосрочные тренды предыдущих значений временного ряда. Полученные прогнозные признаки далее обрабатываются декодировщиком модели TCN, выход которого определяет прогнозные значения временного ряда. По результатам экспериментальных исследований делается вывод о том, что модель TCN-LSTM показывает лучшие результаты по точности прогнозных значений в сравнении с моделями на основе архитектур отдельных нейронных сетей.

Заключение. На основе проведенного обзора можно заключить, что для анализа различных временных рядов, необходимо применять различные методы.

Библиографический список

1. Артюшин В.О., Дергузов К.Ю., Рябинин М.О., Плотников В.П. Выявление аномалий в многомерных временных рядах датчика с использованием машинного обучения // Наука и бизнес: пути развития. 2022. № 4(130). С. 29-35.
2. Катенко Ю.В. Алгоритм выявления аномалий во временных рядах при анализе данных банковских и телекоммуникационных систем // Наука настоящего и будущего. 2018. Т. 1. С. 57-61.
3. Чесноков М.Ю. Поиск аномалий во временных рядах на основе ансамблей алгоритмов DBSCAN // Искусственный интеллект и принятие решений. 2018. № 1. С. 99-107.
4. Голубчикова И.С. Исследование применимости методов обнаружения аномалий во временных рядах // Электронные средства и системы управления. Материалы докладов Международной научно-практической конференции. 2017. № 1-2. С. 160-163.
5. Соболев К.В. Автоматический поиск аномалий во временных рядах: матер. канд. диссер. Москва, 2018. URL: <https://cs.mipt.ru/wp/wpcontent/uploads/2018/06/%D0%A1%D0%BE%D0%B1%D0%BE%D0%BB%D0%B5%D0%B2-%D0%9A.%D0%92.pdf>.
6. Девришев Н.Э., Хэ Ю., Петросян О.Л. Обнаружение аномалий во временных рядах с помощью методов прогнозирования // Процессы управления и устойчивость. 2022. Т. 9. № 1. С. 202-209.
7. Yangdong H., Jibao Zh. Temporal Convolutional Networks for Anomaly Detection in Time Series // Conf. Series: Journal of Physics. 2019. No. 1213.
8. Mezina A., Burget R., Travieso-Gonzalez C.M. Network Anomaly Detection With Temporal Convolutional Network and U-Net Model // IEEE Access. 2021. Т. 9. С. 143608-143622.
9. Емалетдинова Л.Ю., Вильданов Н.Р., Катаев А.С. Использование нейросетевой модели TCN-LSTM для прогнозирования значений временного ряда // Научно-технический вестник Поволжья. 2023. № 6. С. 62-64.