

Применение нейронных сетей для прогнозирования электропотребления мегаполиса*

Вялкова С.А., Надтока И. И., Корнюкова О.А.

ЮРГПУ (НПИ) им. М.И. Платова,

г. Новочеркасск, Российская Федерация

ii_nadtoka@mail.ru, mazaeva_sveta@mail.ru, korniyukova_o@mail.ru

Аннотация. Для краткосрочного прогнозирования суточных графиков активной мощности г. Москвы предложена модель, сформированная на основе алгоритмов нейронной сети с учетом фактических и прогнозных данных по температуре воздуха, облачности, осадкам и естественной освещенности. Для прогнозирования суточных графиков активной мощности гибридная модель, основанная на многомерном сингулярном спектральном анализе и нечетких нейронных сетей. В этой модели временные ряды электропотребления и метеофакторов разлагаются на независимые компоненты, с помощью которых формируются аддитивные трендовые, гармонические и случайные составляющие, используемые в модуле нечеткой нейронной сети.

Исходными данными являлись архивы временных рядов электропотребления, температуры воздуха, облачности, осадков и естественной освещенности для территории г. Москвы за период с 2017 г. по 2019 г. Прогнозные данные естественной освещенности получены с помощью нейронной сети с долгосрочной памятью LSTM.

Выполнены краткосрочные прогнозы суточных графиков активной мощности для августа 2019 г. В результатах краткосрочного прогнозирования суточных графиков активной мощности показано, что в большинстве тестовых примеров получены результаты в пределах допустимых погрешностей.

Ключевые слова: краткосрочное прогнозирование активной мощности, температура воздуха, естественная освещенность, облачность, осадки, нейронная сеть с долгосрочной памятью LSTM.

ВВЕДЕНИЕ

В данной статье приведены результаты прогнозирования суточных графиков активной мощности с учетом прогнозных данных температуры воздуха, облачности, осадков и естественной освещенности для г. Москвы.

Форма суточных графиков характерна для энергосистем с большой долей промышленных и бытовых потребителей, сосредоточенных в основном в крупных городах и значительно отличаются по форме от других суточных графиков энергосистем, представленных в ряде работ [1-4] и др. Основным отличием электропотребления мегаполиса является влияние большего количества факторов, чем в меньших по мощности энергосистемах, что значительно усложняет задачу краткосрочного прогнозирования [5, 6].

При прогнозировании суточных графиков активной мощности используется большое количество различных

методов [1-3]. Все эти методы используют данные суточных графиков активной мощности, в большинстве из них прогнозирование выполняется с учетом различных факторов, влияющих на электропотребление [1-4]. Основными метеофакторами, влияющими на электропотребление и учитываемыми в прогнозных моделях являются температура воздуха, естественная освещенность, облачность и осадки [5-8].

Перспективным направлением при краткосрочном прогнозировании суточных графиков активной мощности энергообъединений и энергосистем является использование нейронных сетей [9-11].

Нейронные сети широко применяются в прогнозировании различных временных рядов электропотребления, однако традиционные нейронные сети не обладают свойством сохранения информации (отсутствует память), они, как правило, смешивают данные все в одну статистическую выборку то, что встречается вначале, быстро теряется. Решить эту проблему помогают рекуррентные нейронные сети с долгосрочной памятью LSTM (Long Short-Term Memory) эти сети умеют связывать предыдущие данные с текущими [12-13].

Сеть LSTM имеет особую разновидность архитектуры, способную к обучению долгосрочным зависимостям при помощи циклов, которые позволяют информации сохраняться. Такая сеть обрабатывает временной ряд шаг за шагом [14-15].

LSTM применяют для прогнозирования, классификации и обработки последовательных данных в различных сферах жизни [16-17]. На сегодняшний день, сеть LSTM показала, выше точность прогноза погоды, чем традиционные нейронные сети [18-19].

В данной статье для прогнозирования суточных графиков активной мощности использована гибридная модель, а для естественной освещенности нейронная сеть с долгосрочной памятью LSTM.

ПРОБЛЕМЫ ПРИ ПРОГНОЗИРОВАНИИ ЕСТЕСТВЕННОЙ ОСВЕЩЕННОСТИ

В современных условиях для выполнения краткосрочного прогнозирования электропотребления с учетом фактических и прогнозных метеофакторов, существуют проблемы учета прогнозов естественной освещенности. Проблемы учета заключаются в следующем:

1) в отсутствии прогнозных данных естественной

* Статья публикуется по рекомендации программного комитета Всероссийской научно-технической конференции "Пром-Инжиниринг", <https://icie-rus.org>

освещенности связанных с тем, что существующие метеостанции и программные аппаратные комплексы в региональных диспетчерских управлениях, которые используют ПАК «Метео», не предоставляют информацию о прогнозных значениях естественной освещенности, а прогнозируют облачность и осадки с большой дискретностью (6 часов) в определенные часы (3:00, 9:00, 15:00, 21:00) либо средние значения за сутки;

2) прогнозирование облачности выполняется с низкой точностью «визуально», т.к. основывается на картах погоды при помощи которых, определяют облачность в баллах: 1 – «ясно», 2 – «пасмурно», 3 – «малооблачно», 4 – «облачно»;

3) в прогнозировании осадков с низкой точностью: «слабый дождь», «умеренный дождь», «слабый снег», «умеренный снег», «без осадков».

Все вышеперечисленные проблемы ведут к снижению точности краткосрочного прогнозирования суточных графиков активной мощности с использованием в качестве исходных данных освещенности, облачности и осадков.

Модель для прогнозирования нейронной сетью с долгой краткосрочной памятью LSTM

Структура алгоритма LSTM-сети используемой в модели прогнозирования суточных графиков естественной освещенности, состоящей из четырех слоев представлена на рис. 1.




Рис. 1. Обобщенная структура LSTM-сети

Основная идея LSTM состоит в том, чтобы «запомнить» важные части временного ряда, и «забыть» о менее значимых. Это достигается за счет так называемых «ворот», т. е. повторяющихся корректировок веса по мере обучения нейронной сети.

Состояние ячейки напоминает конвейерную ленту. Она проходит напрямую через всю цепочку, участвуя лишь в нескольких линейных преобразованиях. Информация может легко течь по ней, не подвергаясь изменениям. Тем не менее, LSTM может удалять информацию из состояния ячейки; этот процесс регулируется структурами, называемыми фильтрами («ворота»). «Ворота» сигмоидальный слой – это способ опционального пропуска информации. Он возвращает числа от нуля до единицы, которые обозначают, какую долю каждого блока информации следует пропустить дальше по сети. Ноль в данном случае означает «не пропускать ничего», единица – «пропустить все» [15-17].

На рис. 1 каждая линия переносит целый вектор от входа одного узла до входа другого. «Точками» обозначены «поточечные операции», такие, как сложение векторов, а желтые прямоугольники – это обученные слои нейронной сети. Сливающиеся линии означают объединение, а разветвляющиеся стрелки говорят о том, что данные копируются и копии уходят в разные компоненты сети.

Архитектура LSTM состоит из одного модуля, модуля памяти (также известного как модуль LSTM). Блок LSTM состоит из четырех нейронных сетей с прямой связью. Каждая из этих нейронных сетей состоит из входного слоя и выходного слоя. В каждой из этих нейронных сетей входные нейроны связаны со всеми выходными нейронами.

1. Первая нейронная сеть («ворота забывания») – удаление информации из «памяти», на основе векторов входного - $X(t)$ и скрытого состояния $h(t-1)$, которые путем умножения поэлементно на вектор-памяти $C(t-1)$. При умножении информация во входном векторе со значением равным 1- имеет значение, а 0 - не имеет.

2. Вторая и третья нейронные сети («входные ворота и память кандидатов») – вставка новой информации в вектор-памяти. После удаления части информации из вектора-памяти, полученной на входе $C(t-1)$, добавляют новую из вектора - кандидата $C(t)$. Вектор-память и вектор-кандидат умножаются друг на друга, элемент за элементом, получая новый вектор память-кандидат. Для вектора-кандидата используется функция гиперболического тангенса.

3. Четвертая нейронная сеть («выходные ворота»), память-кандидат, используется для создания новой информации-кандидата, которая будет вставлена в память следующего модуля LSTM.

Обучение нейронной сети происходит при помощи метода обратного распространения ошибки [12]. Теория данного алгоритма LSTM-сети подробно описана в [12-13].

Исходные данные для прогнозирования

Исходными данными для моделирования и прогнозирования в настоящей статье являлись архивные данные активной мощности и метеофакторов территории г. Москвы, предоставленные филиалом ОАО «СО ЕЭС» «Региональное диспетчерское управление энергосистемы Москвы и Московской области» (Московское РДУ) [20].

Для исследований были использованы данные по электропотреблению, температуре воздуха и естественной освещенности, полученные из архивов Московского РДУ в виде графиков, представляющих собой последовательности значений, регистрируемых через промежуток времени 1 час.

Для сбора данных естественной освещенности и формирования предыстории её значений была создана автоматическая система контроля освещенности на территории г. Москвы, которая обеспечивает решение следующей задачи – формирования архивов показателей освещенности для их последующего использования в системе прогнозирования электропотребления с учетом метеофакторов.

В качестве прогнозных данных облачности и осадков использовались среднесуточные значения, а также их показания в часы (3:00, 9:00, 15:00, 21:00).

Модель прогнозирования естественной освещенности

Прогнозирование естественной освещенности и активной мощности выполнялось на языке Python с помощью библиотек pandas, numpy, pytorch. Нейронная сеть LSTM была создана при помощи алгоритма представленного в [18].

Были выбраны следующие параметры настройки сети LSTM: тестовый период равный 24; период обучения – 96; количество эпох обучения – 400.

Временной интервал исходных данных естественной освещенности был выбран в соответствии с интенсивностью освещенности для территории г. Москвы рис. 2.




Рис. 2. Диаграмма среднемесячных значений суточных графиков естественной освещенности за три года (1.01.2017-31.12.2019 гг.)

Исходные данные естественной освещенности для трех лет (2017-2019 гг.) сортировались по следующим условиям:

- 1) по среднесуточным баллам облачности $\bar{O}(t)$: «ясно» – $\bar{O}(t) \in [0;1]$; «пасмурно» – $\bar{O}(t) \in (1;1.5]$; «малооблачно» – $\bar{O}(t) \in [1.5;2]$; «облачно» – $\bar{O}(t) \in 2$;
- 2) по прогнозируемым осадкам («слабый дождь», «умеренный дождь», «слабый снег», «умеренный снег», «б/о») в часы (3:00, 9:00, 15:00, 21:00);
- 3) по часам восхода и захода Солнца прогнозируемого месяца.

Ошибка прогнозирования для естественной освещенности была рассчитана по формуле:

$$\tilde{\varepsilon}_{MAPE} = \frac{1}{24} \sum_{i=1}^{24} |E_{\phi i} - E_{pi}|, \quad (1)$$

где $E_{\phi i}$, E_{pi} – прогнозное и фактическое значения естественной освещенности для i -го часа суток, $i = 1, 2, \dots, 24$.

Количество исходных данных для прогнозирования равно $N = 24 \times d$ часов, где d количество выбранных дней с учетом прогнозной облачности из ранее приведенного интервала исходных данных по типам облачности (рис. 3).




Рис. 3. Пример исходных данных $E(t)$ для типа облачности «ясно» (прогнозная облачность $\bar{O}_{II}(t) = 1$) для прогноза на 12.08.19 г.

Средняя ошибка прогнозирования суточного графика естественной освещенности составила 4506 лк (рис. 4).




Рис. 4. Пример прогнозирования графиков значений фактической (красная линия) и прогнозной (зеленая линия) освещенности 12.08.19 г.

Максимальная ошибка была получена для 14.08.19 г., из-за неточных данных прогнозных осадков («без осадков»), фактически значения («слабый дождь», «умеренный дождь»). Среднесуточная абсолютная ошибка составила 21795 лк, превысив допустимую погрешность (10000 лк) на 11795 лк.

Полученные прогнозные значения суточных графиков естественной освещенности были использованы при прогнозировании активной мощности в гибридной модели.

ГИБРИДНАЯ МОДЕЛЬ ПРОГНОЗИРОВАНИЯ АКТИВНОЙ МОЩНОСТИ

Метод MSSA (MSSA – Multi-Channel Singular Spectrum Analysis) является методом моделирования временных рядов, позволяющим воспроизводить отдельные составляющие ряда с учетом влияющих метеофакторов на исследуемый ряд [21-24].

Поведение временного ряда представляют в виде суммы аддитивных составляющих:

$$P(t) = P_T(t) + P_I(t) + P_{СЛ}(t),$$

где $P_T(t)$ – трендовые, $P_I(t)$ – гармонические (сезонные), $P_{СЛ}(t)$ случайные составляющие.

После разложения временного ряда на составляющие методом MSSA осуществлялось прогнозирование нейронной нечеткой сетью Такаги-Сугено-Канга (ННС) [25]. Выделенные составляющие трендовая и гармоническая прогнозировались отдельно ННС с учетом данных фактических и прогнозных метеофакторов [25]. Гибридная модель и результаты прогнозирования подробно описаны в работах [5, 6].

Временной интервал исходных данных для прогнозирования активной мощности $P(t)$, температуры воздуха $\theta(t)$ и освещенности $E(t)$ был выбран в 2017, 2018 и 2019 годах.

Длина входного интервала d алгоритма прогнозирования $P(t)$ для разных типов суток составила:

- для рабочих $d=15$ суток;
- для выходных, послепраздничных, предпраздничных, нерегулярных (в днях при переносе праздничных дней) $d=60$ суток;
- для праздничных d равно количеству праздников в прогнозируемом месяце за три предыдущих года.

Количество исходных данных активной мощности $P(t)$ равно $\tilde{N} = 24 \times d$ часов, где d количество выбранных дней с учетом типа дня суток из ранее приведенного интервала исходных данных. Учитываются также данные за текущие сутки, т.е. сутки $H+X$, где H – недостающие часы текущих суток.

Учет температуры воздуха и естественной освещенности в описываемой ННС осуществлён путем добавления данных средних значений фактических $\bar{\theta}(t)$, $\bar{E}(t)$ и прогнозных $\bar{\theta}_n(t)$, $\bar{E}_n(t)$ во входной слой [25].

РЕЗУЛЬТАТЫ КРАТКОСРОЧНОГО ПРОГНОЗИРОВАНИЯ АКТИВНОЙ МОЩНОСТИ

Для оценки качества полученных прогнозов активной мощности были рассчитаны значения ошибки за сутки в процентах по формуле (1) [20].

$$\varepsilon_{MAPE} = \frac{1}{24} \sum_{i=1}^{24} \left| \frac{p_{\phi_i} - p_{\pi_i}}{p_{\phi_i}} \right| \cdot 100\%, \quad (2)$$

где $i = 1, 2, \dots, 24$ – номер часа; p_{ϕ_i} – фактическое значение активной мощности для i -го часа; p_{π_i} – значение активной мощности для i -го часа, полученное с помощью прогнозной модели.

Пример прогноза графиков активной мощности с учетом прогнозных и фактических значений метеофакторов представлен на рис 5. Ошибка прогнозирования суточного графика активной мощности для 12.08.19 г. составила 1,44 %.

При выполнении прогнозирования с учетом прогнозных метеофакторов ошибки не превысили допустимого значения, кроме 17.08.2022 г. (суббота), величина ошибки прогноза активной мощности составила - 2,53 %.

Среднемесячная ошибка для августа 2019 г. с учетом фактических метеофакторов составила 1,32 %, а с учетом прогнозных метеофакторов составила 1,8 %. Для других выборочных месяцев (февраля, мая, ноября) в течение 2019 г. были получены аналогичные результаты прогнозов.




Рис. 5. Примеры прогноза графиков активной мощности для 12.08.19 г. (понедельник)

ЗАКЛЮЧЕНИЕ (Выводы)

Предложенная модель краткосрочного прогнозирования суточных графиков активной мощности г. Москвы с учетом прогнозных данных естественной освещенности дает результаты средней абсолютной процентной ошибки за сутки менее 2%, что соответствует требованиям методики ОАО «СО ЕЭС» [20].

Необходимо провести дополнительные исследования по совершенствованию структуры и подбору экспериментально настраиваемых параметров рассмотренной LSTM сети с целью уменьшения ошибки прогноза.

Исходя из полученных результатов, необходимо продолжать исследования алгоритма LSTM-сети в течение года с целью выявления сочетания месяца и состояния погоды, при которых получаются наилучшие результаты прогнозирования, но необходимо отметить сложность реализации и длительность работы разработанной программы при расчёте прогноза.

ЛИТЕРАТУРА

1. Бэнн Д.В. Сравнительные модели прогнозирования электрической нагрузки: пер с англ. / Д.В. Бэнн, Е.Д. Фармер. – М.: Энергоатомиздат, 1987. – 200 с.
2. Куренный Э.Г., Прогнозирование электрических нагрузок / Э.Г. Куренный, Е.Н. Дмитриева и др. // Изв. АН СССР. Энергетика и транспорт. – 1988. – № 2. – С. 89-100.
3. Шумилова Г.П. Прогнозирование электрических нагрузок при оперативном управлении электроэнергетическими системами на основе нейросетевых структур / Г.П. Шумилова, Н.Э. Готтман, Т.Б. Старцева. – Екатеринбург: УрОРАН, 2008. – 89 с.
4. Грицай А.С. Гибридный метод краткосрочного прогнозирования потребления электрической энергии для энергосбытового предприятия с учетом метеофакторов: дис. ... канд. техн. наук. – Омск, 2017. – 150 с.
5. Vyalkova S. Short-term forecasting using fuzzy neural network accountability air temperature and natural lighting / S. Vyalkova, I. Nadtoke // 2nd International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 19-20 May 2016, Chelyabinsk, Russia, 2016. – URL: <https://ieeexplore.ieee.org/document/7910991>.
6. Nadtoke I. Hybrid Speculation Model of Energy Consumption Based on Multivariate Singular Spectrum Analysis and Neu-

ral Fuzzy Network / I. Nadtocka, S. Vyalkova // 2019 International Conference on Industrial Engineering, Applications and Manufacturing (ICIEAM), 25-29 March 2019, IEEE, Sochi, Russia, 2019. – URL: <https://ieeexplore.ieee.org/document/8742971>.

7. Аль Зихери Баласим Мохаммед Повышение точности краткосрочного прогнозирования электрической нагрузки потребителей региона с учетом метеофакторов на основе метода опорных векторов: дисс. ... канд. техн. наук. – Новочеркасск, 2015. – 181 с.

8. Бугаец В.А. Краткосрочное прогнозирование электропотребления энергорайонов и региона с учетом метеофакторов: дисс. ... канд. техн. наук. – Новочеркасск, 2015. – 241 с.

9. Сердюкова Г.Н. Прогнозирование электропотребления с использованием нейро-нечетких сетей. – Харьков: Харьковский политехнический институт, 2008. – С. 229-233.

10. Анушина Е.С. Система краткосрочного прогнозирования электрической нагрузки: дис. канд. техн. наук. – Санкт-Петербург, 2009. – 137 с.

11. Nadtocka I. Mathematical modeling and short-term forecasting of electricity consumption of the power system, with due account of air temperature and natural illumination, based on support vector machine and particle swarm / I. Nadtocka, Balasim M. Al-Zihery // International Conference on Industrial Engineering, Procedia Engineering 129 (2015) 657 – 663, ICIE 2016, Chelyabinsk, 2016. – URL: <https://www.sciencedirect.com/science/article/pii/S1877705815039715>.

12. Lipton Zachary C. A Critical Review of Recurrent Neural Networks for Sequence Learning / Zachary C. Lipton, John Berkowitz, Charles Elkan // CoRR, abs/1505.06449, 2015. – URL: <https://arxiv.org/pdf/1506.00019.pdf>

13. Christopher Olah, Understanding LSTM Networks. Posted on August 27, 2015. – URL: <http://colah.github.io/posts/2015-08-Understanding-LSTMs>.

14. Ottavio Calzone, An Intuitive Explanation of LSTM, 2015. – URL: <https://medium.com/@ottaviocalzone/an-intuitive-explanation-of-lstm-a035eb6ab42c>.

15. Vijaysinh Lendave, How To Do Multivariate Time Series Forecasting Using LSTM, Explain The Newest Technologies, And Their Commercial, Social And Political Impact, July

11, 2021. – URL: <https://analyticsindiamag.com/how-to-do-multivariate-time-series-forecasting-using-lstm/>.

16. Long Short-Term Memory (LSTM), Dive into Deep Learning. – URL: https://d2l.ai/chapter_recurrent-modern/lstm.html.

17. Eligijus Bujokas, Single and Multi-Step Temperature Time Series Forecasting for Vilnius Using LSTM Deep Learning Model, Medium, 2020. – URL: <https://towardsdatascience.com/single-and-multi-step-temperature-time-series-forecasting-for-vilnius-using-lstm-deep-learning-b9719a0009de>.

18. Jingwei Hou, Yanjuan Wang, Ji Zhou, Qiong Tian. Prediction of hourly air temperature based on CNN-LSTM. – URL: <https://www.tandfonline.com/doi/full/10.1080/19475705.2022.2102942>.

19. Chen Guici, Daily Weather Forecasting Based on Deep Learning Model: A Case Study of Shenzhen City / Chen Guici, Liu Sijia, Jiang Feng // MDPI journals, 15 June 2022, China, 2022, – URL: <https://www.mdpi.com/2073-4433/13/8/1208>.

20. Методика контроля точности прогноза потребления: Распоряжение руководителя оперативного штаба по совершенствованию конкурентного балансирующего рынка ОАО «Системный оператор единой энергетической системы» от 14 апреля 2011 № 132.

21. Голяндина Н.Э. Метод «Гусеница» – SSA: анализ временных рядов: учеб. пособие. – СПб., 2004. – 76 с.

22. Голяндина Н.Э., Варианты метода «Гусеница» – SSA для анализа многомерных временных рядов: учеб. пособие. – СПб., 2004. – 30 с.

23. Александров Ф.И. Разработка программного комплекса автоматического выделения и прогноза аддитивных компонент временных рядов в рамках подхода «Гусеница»-SSA: дис. ... канд. физ.-матем. наук. – Санкт-Петербург, 2006. – 152 с.

24. Щелкалин В.Н., Гибридные модели и методы прогнозирования временных рядов на основе методов "Гусеница"-SSA и Бокса-Дженкинса // Восточно-Европейский журнал передовых технологий. – 2014. – № 5(4). – С. 43-62.

25. Осовский С. Нейронные сети для обработки информации. – М.: Финансы и статистика, 2004. – 344 с.

DOI: 10.24892/RIJIE/20230403

Application of Neural Networks to Predict Power Consumption of a Megapolis

Vyalkova S., Nadtocka I., Korniyukova O.

Platov South-Russian State Polytechnic University (NPI)

Novocherkassk, Russia

mazaeva_sveta@mail.ru, ii_nadtocka@mail.ru, korniyukova_o@mail.ru

Abstract. A model for daily schedules short-term forecasting of active power in Moscow is proposed in the article. It is formed on the basis of neural network algorithms, taking into account actual and forecast data on air temperature, cloudiness, precipitation and natural light. To predict daily active power curves, a hybrid model based on multivariate singular spectral analysis and fuzzy neural networks is proposed. Time series of power consumption and meteorological factors are decomposed into independent components in this model, with the help of which additive trend, harmonic and random components, used in the fuzzy neural network module, are formed.

The initial data were archives of power consumption time se-

ries, air temperature, cloudiness, precipitation and natural light for the territory of Moscow in the period from 2017 to 2019. Predictive data on natural light were obtained using a neural network with long-term memory LSTM.

Short-term forecasts of daily active power schedules for August 2019 were made. The results of short-term forecasting of daily active power schedules show that in most test cases the outcomes were obtained within acceptable errors.

Keywords: short-term active power prediction, air temperature, daylight, cloudiness, precipitation, neural network with long-term memory LSTM.