

Вестник Череповецкого государственного университета. 2021. № 5 (104). С. 46–58.
Cherepovets State University Bulletin, 2021, no. 5 (104), pp. 46–58.

Научная статья

УДК 004.896

<https://doi.org/10.23859/1994-0637-2021-5-104-4>

**Особенности формирования обучающей выборки данных при
краткосрочном прогнозировании электропотребления гарантирующего
поставщика с помощью инструментов глубоких нейронных сетей**

**Станислав Олегович Хомутов¹,
Николай Александрович Серебряков²✉**

^{1,2}Алтайский государственный технический университет им. И. И. Ползунова,
Барнаул, Россия,

¹homutov.so@yandex.ru, <https://orcid.org/0000-0002-8430-9384>

²na_serebryakov@altke.ru✉, <https://orcid.org/0000-0001-7428-7364>

Аннотация. Данная статья посвящена вопросам формирования выборки данных, необходимой для обучения и тестирования интеллектуальных алгоритмов краткосрочного прогнозирования почасового электропотребления гарантирующего поставщика. Описан алгоритм формирования обучающей выборки на основании ретроспективных данных об электропотреблении и величине влияющих факторов. Выполнено исследование законов распределения величин факторов, имеющих случайный характер: почасового электропотребления, температуры наружного воздуха, дисперсии суточных значений температуры, а также количества осадков в светлое время суток.

Ключевые слова: краткосрочное прогнозирование электропотребления, обучающая выборка, влияющие факторы, закон распределения случайной величины, критерий согласия Пирсона

Для цитирования: Хомутов С. О., Серебряков Н. А. Особенности формирования обучающей выборки данных при краткосрочном прогнозировании электропотребления гарантирующего поставщика с помощью инструментов глубоких нейронных сетей // Вестник Череповецкого государственного университета. 2021. № 5 (104). С. 46–58.
<https://doi.org/10.23859/1994-0637-2021-5-104-4>.

**Characteristics of a training data sample for short-term forecasting of power
consumption of a default supplier applying tools of deep neural networks**

Stanislav O. Khomutov¹, Nikolay A. Serebryakov²✉

^{1,2}Polzunov Altai State Technical University,
Barnaul, Russia,

¹homutov.so@yandex.ru, <https://orcid.org/0000-0002-8430-9384>

²na_serebryakov@altke.ru✉, <https://orcid.org/0000-0001-7428-7364>

Abstract. This article deals with forming a data sample necessary for training and testing intelligent algorithms of a default supplier. The authors describe an algorithm for the formation of a training sample based on retrospective power consumption data and influencing factors. There is a study on the distribution laws of the factors that have a random nature: hourly power consumption, outdoor temperature, dispersion of daily temperature values, as well as the amount of precipitation during the day.

Keywords: short-term forecasting of electric load, training sample, influencing factors, distribution law of a random variable, Pearson's chi-squared test

For citation: Khomutov S. O., Serebryakov N. A. Characteristics of a training data sample for short-term forecasting of power consumption of a default supplier applying tools of deep neural networks. *Cherepovets State University Bulletin*, 2021, no. 5 (104), pp. 46–58. (In Russ.). <https://doi.org/10.23859/1994-0637-2021-5-104-4>.

Введение

В настоящее время закупка электроэнергии гарантирующими поставщиками (далее – ГП) на оптовом рынке электроэнергии и мощности (далее – ОРЭМ) предполагает краткосрочное прогнозирование собственного почасового электропотребления. В условиях функционирования ОРЭМ точность прогнозов потребления существенно влияет на технологические и экономические показатели энергосистемы¹. Данный вид прогнозирования важен при управлении энергосистемой, пусках энергоблоков, экономической диспетчеризации, а также на рынках электроэнергии². Результаты краткосрочного прогнозирования используются администратором торговой системы ОРЭМ при составлении торгового графика и системным оператором при формировании диспетчерского графика выработки и потребления электроэнергии. Ошибки при создании краткосрочного прогноза электропотребления ГП приводят к затруднению оптимизации режима энергосистемы, следствием чего являются необоснованные пуски в работу и остановки генерирующего оборудования, а также выбор неоптимальной схемы электрических сетей. В связи с этим торговля отклонениями фактического электропотребления от прогнозного происходит по невыгодной цене. Данное обстоятельство приводит к ухудшению финансовых показателей ГП от торговли электроэнергией, а также к увеличению цены для конечных потребителей.

Объемы потребления электроэнергии любого объекта зависят от множества факторов. В работе «Анализ факторов, влияющих на совокупное электропотребление

¹ Доманов В. И., Билалова А. И. Прогнозирование объемов энергопотребления в зависимости от исходной информации // Вестник ЮУрГУ. Серия «Энергетика». 2016. Т. 16, № 2. С. 59–65. <https://doi.org/10.14529/power160208>.

² Bouktif S., Fiaz A., Ouni A., Serhani M. A. Optimal Deep Learning LSTM Model for Electric Load Forecasting using Feature Selection and Genetic Algorithm: Comparison with Machine Learning Approaches // *Energies*. 2018. Vol. 11, iss. 7. URL: <https://www.mdpi.com/1996-1073/11/7/1636> (дата обращения: 02.03.2021).

гарантирующего поставщика»¹ авторами проведено подробное исследование воздействия на почасовое электропотребление групп точек поставки (далее – ГТП) ГП. В результате выполненного анализа установлено, что почасовое электропотребление обуславливают следующие показатели:

– фактическое почасовое потребление электроэнергии за предыдущие периоды (случайная величина);

- день в году;
- день недели;
- час суток;
- государственные и религиозные праздники;
- каникулы в образовательных учреждениях;
- наличие центрального отопления в населенных пунктах, обслуживаемых ГП;
- наличие горячего водоснабжения в населенных пунктах, обслуживаемых ГП;
- наличие холодного водоснабжения в населенных пунктах, обслуживаемых

ГП;

- относительная длительность светового дня;
- режим работы крупных потребителей;
- ветро-холодовой индекс (случайная величина);
- дисперсия суточных значений температуры воздуха, учитывающая динамику изменений температуры (случайная величина);
- количество осадков, выпавших в светлое время суток (случайная величина).

Формализация задачи краткосрочного прогнозирования электропотребления (Short-term Load Forecasting – STLF) затруднена необходимостью учета большого количества факторов, в том числе случайного характера. В результате проведенного в работе В. З. Манусова, Е. В. Бирюкова «Краткосрочное прогнозирование электрической нагрузки на основе нечеткой нейронной сети и ее сравнение с другими методами»² сравнительного анализа методов краткосрочного прогнозирования электропотребления установлено, что стандартные статистические методы не обеспечивают высокой точности прогноза. В настоящее время методы искусственного интеллекта и глубокого машинного обучения широко применяются для решения слабоформализуемых задач³. Точность краткосрочного прогнозирования электропотребления при использовании методов искусственного интеллекта зависит как от эффективности

¹ Серебряков Н. А. Анализ факторов, влияющих на совокупное электропотребление гарантирующего поставщика // Вестник Иркутского государственного технического университета. 2020. Т. 24. № 2. С. 366–381. <https://doi.org/10.21285/1814-3520-2020-2-366-381>.

² Манусов В. З., Бирюков Е. В. Краткосрочное прогнозирование электрической нагрузки на основе нечеткой нейронной сети и ее сравнение с другими методами // Известия Томского политехнического университета. 2006. Т. 309, № 6. С. 153–158.

³ Станкевич Т. С. Разработка метода оперативного прогнозирования динамики развития лесного пожара посредством искусственного интеллекта и глубокого машинного обучения // Вестник Иркутского государственного технического университета. 2018. Т. 22, № 9. С. 111–120. <https://doi.org/10.21285/1814-3520-2018-9-111-120>.

выбираемых алгоритмов, так и от качества проанализированной информации и возможности включения значимых внешних факторов в модель¹. Иными словами, обучающая выборка данных, необходимая для обучения и тестирования прогнозных алгоритмов, должна содержать статистическую информацию о величине основных влияющих факторов. Кроме того, важным аспектом формирования и анализа обучающей выборки является исследование законов распределения величин факторов, имеющих случайный характер. Знание закономерностей распределения ретроспективных данных по области их обнаружения позволяет улучшить качество обучающей выборки за счет использования подходящих методов предобработки статистической информации, таких как фильтрация шумов, уплотнение данных, а также пакетная нормализация².

Основная часть

Начальным этапом формирования обучающей выборки служит сбор статистических данных о величине всех влияющих факторов. Исходной для создания обучающей выборки являлась следующая статистическая информация за период с 01.04.2016 г. по 30.12.2019 г.:

- величина почасового электропотребления ГТП «Южная»;
- метеорологические условия в г. Рубцовске;
- режим работы крупных потребителей ГТП «Южная» с максимальной мощностью свыше 670 кВт;
- количество отключений электросетевого оборудования, питающего потребителей ГТП «Южная»;
- периоды отопительного сезона и ремонтных работ на водоснабжающем оборудовании в Рубцовском районе.

Использование более ранних статистических данных ухудшает результаты прогнозирования вследствие того, что 27.03.2016 г. в Алтайском крае произошел последний переход на летнее время; в результате этого существенно изменилась форма суточных графиков электропотребления.

После сбора статистической информации необходимо проверить ее полноту. При отсутствии каких-либо данных требуется осуществить дополнительный сбор сведений. Когда полнота сбора данных обеспечена, следует произвести дорасчет необходимых величин: ветро-холодового индекса Стедмана³, дисперсии суточных значений температуры воздуха, количества осадков в светлое время суток, относительной дли-

¹ Rajan D. V., Mallick S., Thakur S. S. An efficient approach for short-term load forecasting using historical data // International Journal of Engineering Research & Technology (IJERT). 2012. Vol. 1, iss. 3. URL: <https://goo-gl.ru/zizzs> (дата обращения: 02.03.2021).

² Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. URL: <https://arxiv.org/pdf/1502.03167.pdf> (дата обращения: 02.03.2021).

³ Quayle R. G., Steadman R. G. The Steadman wind chill: An improvement over present scales // Weather and Forecasting. 1998. Vol. 13, iss. 4. P. 1187–1193.

тельности светового дня¹. В табл. 1 представлен фрагмент выборки статистических данных о фактическом электропотреблении ГП и величине основных влияющих факторов.

Таблица 1

**Фрагмент выборки статистических данных о фактическом электропотреблении
ГП и величине основных влияющих факторов**

Наименование фактора	Величина фактора					
	2	3	4	5	6	7
Порядковый номер дня в году	336	336	336	336	336	336
Час суток, часы	0	1	2	3	4	5
Электропотребление, кВт·ч	26314	28988	37280	45798	50184	52550
Ветро-холодовой индекс, °С	–20,00	–20,33	–20,67	–21,00	–20,67	–20,33
Дисперсия температуры	–11,75	–12,71	–13,71	–14,75	–15,54	–16,09
День недели	2	2	2	2	2	2
Признак праздничного и предпраздничного дня	1	1	1	1	1	1
Признак каникул	0	0	0	0	0	0
Количество осадков	0	0	0	0	0	1
Длина светового дня	0,34	0,34	0,34	0,34	0,34	0,34
Признак наличия центрального отопления	1	1	1	1	1	1
Признак наличия горячей воды	1	1	1	1	1	1
Признак наличия холодной воды	1	1	1	1	1	1
Режим работы крупного потребителя электроэнергии	1	1	1	1	1	1

Обучающая выборка формируется на основании выборки статистических данных о фактических величинах влияющих факторов (см. табл. 1) путем приведения данных к диапазону $[0; 1]$ ². Такая нормализация необходима для удобства представле-

¹ Хомутов С. О., Сташко В. И., Серебряков Н. А. Повышение точности краткосрочного прогнозирования электропотребления групп точек поставки электроэнергии гарантирующих поставщиков второго уровня // Известия Томского политехнического университета. Инжиниринг георесурсов. 2020. Т. 331, № 6. С. 128–140. <https://doi.org/10.18799/24131830/2020/6/2682>.

² Liu N., Tang Q., Zhang J., Fan W., Liu J. A hybrid forecasting model with parameter optimization for short-term load forecasting of micro-grids // Applied Energy. 2014. Vol. 129. P. 336–345.

ния информации прогнозной модели, а также для того, чтобы избежать ситуации, когда фактору придется необоснованно большое / малое значение только исходя из его величины. Статистический материал о величине факторов, влияющих на почасовое электропотребление ГТП ГП, нормализован на основании выражения:

$$x_{\text{норм}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \cdot 0,9 + 0,05, \quad (1)$$

где $x_{\text{норм}}$ – нормализованное значение входных данных; x – фактическое значение входных данных; $x_{\min}, x_{\max}$ – минимальное и максимальное значения ряда входных данных.

Границы диапазона нормализации [0,05; 0,95] установлены исходя из особенностей формы графика сигмоидальной функции активации с учетом того факта, что вблизи границ области определения (вблизи 0 и 1) данная функция имеет зоны насыщения.

Далее весь массив обучающих данных произвольным образом делится на тренировочные и тестовые выборки в соотношении 9:1. Важным моментом является тот факт, что тестовая выборка не должна быть задействована в процессе обучения нейросетевой модели. На рис. 1 изображена блок-схема алгоритма формирования тренировочной и тестовой выборок данных.




Рис. 1. Блок-схема алгоритма формирования тренировочной и тестовой выборок данных

Описание алгоритма формирования обучающей выборки представлено ниже.

Начало.

Шаг 1: Сбор данных о величине влияющих факторов.

Шаг 2: Проверка полноты сбора данных. На данном шаге информация проверяется на предмет ошибок и пропусков. Если в данных имеются отсутствующие значения, то происходит дополнительный сбор информации до того момента, пока не бу-

дет обеспечена полнота сбора.

Шаг 3: Расчет необходимых вспомогательных величин.

Шаг 4: Нормализация данных.

Шаг 5: Разделение обучающей выборки на тренировочную и тестовую выборки данных.

Шаг 6: Вывод данных тренировочной и тестовой выборок.

Конец.

После формирования обучающей выборки необходимо установить закон распределения фактических величин факторов. Понимание закономерностей распределения данных по области их обнаружения позволяет принять решение о необходимости применения средств предобработки исходной информации. Наиболее предпочтительны следующие законы распределения данных обучающей выборки: равномерный, показательный и нормальный. Информация о величинах детерминированных факторов имеет равномерный закон распределения. Для факторов случайного характера необходимо произвести проверку соответствия фактического распределения данных теоретическому. С этой целью выборка данных о фактических величинах факторов разбивается на несколько равных диапазонов. Далее визуально выбирается наиболее подходящий закон распределения случайных величин. После этого производится проверка гипотезы о соответствии фактического распределения случайной величины теоретическому закону. В настоящем исследовании данная проверка выполнялась с помощью критерия согласия Пирсона (χ^2). В табл. 2 представлены результаты проверки соответствия распределения случайной величины почасового электропотребления ГП за период с 01.01.2018 г. по 31.12.2018 г. нормальному закону посредством критерия согласия Пирсона (χ^2).

Исходя из данных табл. 2, можно говорить о том, что наблюдаемое значение критерия согласия меньше критического $\chi^2_{\text{набл}} < \chi^2_{\text{кр}}$, т. е. гипотеза о нормальности распределения случайной величины почасового электропотребления ГП верна. Проверка гипотез о виде распределения случайных величин для остальных факторов проводилась аналогичным способом. На рис. 2–5 представлены диаграммы распределения теоретических и фактических частот случайных величин почасового электропотребления ГП, ветро-холодового индекса в г. Рубцовске, дисперсии суточных значений температуры воздуха и количества осадков в светлое время суток за период с 01.01.2018 г. по 31.12.2018 г.

Таблица 2

Результаты проверки соответствия распределения случайной величины почасового электропотребления ГП за период с 01.01.2018 г. по 31.12.2018 г. нормальному закону с помощью критерия согласия Пирсона (χ^2)

Середина диапозона x_i , МВт·ч	Фактические частоты n_i	Теоретические частоты n_i	$\frac{(n_i - n'_i)^2}{n'_i}$
21,71	455	471	0,501
28,35	984	962	0,515
34,99	1667	1716	1,393
41,62	2138	2130	0,029
48,26	1781	1822	0,917
54,90	1112	1074	1,355
61,54	485	436	5,460
68,18	138	149	0,798
Критическое значение критерия согласия $\chi^2_{кр} = 11,07$		Наблюдаемое значение критерия согласия $\chi^2_{набл} = 10,969$	




Рис. 2. Диаграмма распределения теоретических и фактических частот почасовых значений электропотребления ГП за период с 01.01.2018 г. по 31.12.2018 г.




Рис. 3. Диаграмма распределения теоретических и фактических частот почасовых значений ветро-холодового индекса в г. Рубцовске за период с 01.01.2018 г. по 31.12.2018 г.




Рис. 4. Диаграмма распределения теоретических и фактических частот дисперсии суточных значений температуры воздуха за период с 01.01.2018 г. по 31.12.2018 г.




Рис. 5. Диаграмма распределения теоретических и фактических частот величины количества осадков в светлое время суток за период с 01.01.2018 г. по 31.12.2018 г.

На основании диаграмм, представленных на рис. 2–5, можно констатировать следующее:

- фактическое почасовое электропотребление ГП распределено по нормальному закону с математическим ожиданием $m = 42,4$ и среднеквадратичным отклонением $\sigma = 10,61$;
- ветро-холодовой индекс распределен по нормальному закону с математическим ожиданием $m = 1,4$ и среднеквадратичным отклонением $\sigma = 15,65$;
- величина дисперсии суточных значений температуры наружного воздуха, учитывающая направление ее изменений, распределена по нормальному закону с математическим ожиданием $m = 3$ и среднеквадратичным отклонением $\sigma = 21,5$;
- величина количества осадков в светлое время суток распределена по показательному закону с параметром $\lambda = 0,71$.

Поскольку данные обучающей выборки имеют рекомендуемые при использовании искусственных нейронных сетей законы распределения (равномерный, показательный и нормальный), необходимость в применении средств предварительной обработки данных обучающей выборки отсутствует.

Для оценки эффективности описанной выше методики сформированы 3 обучающие выборки, учитывающие различный набор факторов.

Выводы

Важнейшим аспектом краткосрочного прогнозирования электропотребления ГП с помощью инструментов искусственных нейронных сетей является формирование выборки данных, необходимой для обучения и тестирования прогнозных алгоритмов. Обучающая выборка должна содержать информацию о величине всех значимых

факторов, влияющих на электрическую нагрузку ГП. Для улучшения сходимости нейросетевых прогнозных алгоритмов данные обучающей выборки необходимо привести к единому диапазону. Границы диапазона нормализации данных должны быть выбраны исходя из особенностей формы графиков используемых функций активации. Кроме того, важную составляющую формирования обучающей выборки представляет собой анализ законов распределения данных по области их выявления. В ходе настоящего исследования установлено, что данные о факторах электропотребления ГП, ветро-холодового индекса и дисперсии суточных значений температуры воздуха распределены по нормальному закону, а данные о факторе количества осадков в светлое время суток – по показательному закону.

Список источников

Доманов В. И., Билалова А. И. Прогнозирование объемов энергопотребления в зависимости от исходной информации // Вестник ЮУрГУ. Серия «Энергетика». 2016. Т. 16, № 2. С. 59–65. <https://doi.org/10.14529/power160208>.

Манусов В. З., Бирюков Е. В. Краткосрочное прогнозирование электрической нагрузки на основе нечеткой нейронной сети и ее сравнение с другими методами // Известия Томского политехнического университета. 2006. Т. 309, № 6. С. 153–158.

Серебряков Н. А. Анализ факторов, влияющих на совокупное электропотребление гарантирующего поставщика // Вестник Иркутского государственного технического университета. 2020. Т. 24. № 2. С. 366–381. <https://doi.org/10.21285/1814-3520-2020-2-366-381>.

Станкевич Т. С. Разработка метода оперативного прогнозирования динамики развития лесного пожара посредством искусственного интеллекта и глубокого машинного обучения // Вестник Иркутского государственного технического университета. 2018. Т. 22, № 9. С. 111–120. <https://doi.org/10.21285/1814-3520-2018-9-111-120>.

Хомутов С. О., Сташко В. И., Серебряков Н. А. Повышение точности краткосрочного прогнозирования электропотребления групп точек поставки электроэнергии гарантирующих поставщиков второго уровня // Известия Томского политехнического университета. Инжиниринг георесурсов. 2020. Т. 331, № 6. С. 128–140. <https://doi.org/10.18799/24131830/2020/6/2682>.

Bouktif S., Fiaz A., Ouni A., Serhani M. A. Optimal Deep Learning LSTM Model for Electric Load Forecasting using Feature Selection and Genetic Algorithm: Comparison with Machine Learning Approaches // Energies. 2018. Vol. 11, iss. 7. URL: <https://www.mdpi.com/1996-1073/11/7/1636> (дата обращения: 02.03.2021).

Ioffe S., Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. URL: <https://arxiv.org/pdf/1502.03167.pdf> (дата обращения: 02.03.2021).

Liu N., Tang Q., Zhang J., Fan W., Liu J. A hybrid forecasting model with parameter optimization for short-term load forecasting of micro-grids // Applied Energy. 2014. Vol. 129. P. 336–345.

Quayle R. G., Steadman R. G. The Steadman wind chill: An improvement over present scales // Weather and Forecasting. 1998. Vol. 13, iss. 4. P. 1187–1193.

Rajan D. V., Mallick S., Thakur S. S. An efficient approach for short-term load forecasting using historical data // International Journal of Engineering Research & Technology (IJERT). 2012. Vol. 1, iss. 3. URL: <https://goo-gl.ru/zizzs> (дата обращения: 02.03.2021).

References

Domanov V. I., Bilalova A. I. Prognozirovanie ob'emov energopotrebleniia v zavisimosti ot iskhodnoi informatsii [Forecasting power consumption based on source information]. *Vestnik IuUrGU. Seriya "Energetika"* [Bulletin of the South Ural State University. Series "Power engineering"], 2016, vol. 16, no. 2, pp. 59–65. <https://doi.org/10.14529/power160208>.

Manusov V. Z., Biriukov E. V. Kratkosrochnoe prognozirovanie elektricheskoi nagruzki na osnove nechetkoi neironnoi seti i ee sravnenie s drugimi metodami [Short-term load prediction on the bases of fuzzy neural network and its comparison with other methods]. *Izvestiia Tomskogo politekhnicheskogo universiteta* [Bulletin of the Tomsk Polytechnic University.], 2006, vol. 309, no. 6, pp. 153–158.

Serebriakov N. A. Analiz faktorov, vliiaiuschchikh na sovokupnoe elektropotreblenie garantiruiushchego postavshchika [Analysis of factors affecting the electricity consumption of a delivery point cluster default provider]. *Vestnik Irkutskogo gosudarstvennogo tekhnicheskogo universiteta* [Proceedings of Irkutsk State Technical University], 2020, vol. 24, no. 2, pp. 366–381. <https://doi.org/10.21285/1814-3520-2020-2-366-381>.

Stankevich T. S. Razrabotka metoda operativnogo prognozirovaniia dinamiki razvitiia lesnogo pozhara posredstvom iskusstvennogo intellekta i glubokogo mashinnogo obucheniia [Development of operational prediction method of forest fire dynamics based on artificial intelligence and deep machine learning]. *Vestnik Irkutskogo gosudarstvennogo tekhnicheskogo universiteta* [Proceedings of Irkutsk State Technical University], 2018, vol. 22, no. 9, pp. 111–120. <https://doi.org/10.21285/1814-3520-2018-9-111-120>.

Khomutov S. O., Stashko V. I., Serebriakov N. A. Povyshenie tochnosti kratkosrochnogo prognozirovaniia elektropotrebleniia grupp toчек postavki elektroenergii garantiruiushchikh postavshchikov vtorogo urovnia [Improving the accuracy of short-term load forecasting of delivery point cluster of the second level default provider]. *Izvestiia Tomskogo politekhnicheskogo universiteta. Inzhiniring georesursov* [Bulletin of the Tomsk Polytechnic University. Geo Assets Engineering], 2020, vol. 331, no. 6, pp. 128–140. <https://doi.org/10.18799/24131830/2020/6/2682>.

Bouktif S., Fiaz A., Ouni A., Serhani M. A. Optimal Deep Learning LSTM Model for Electric Load Forecasting using Feature Selection and Genetic Algorithm: Comparison with Machine Learning Approaches. *Energies*, 2018, vol. 11, iss. 7. Available at: <https://www.mdpi.com/1996-1073/11/7/1636> (accessed: 02.03.2021).

Ioffe S., Szegedy C. *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. Available at: <https://arxiv.org/pdf/1502.03167.pdf> (accessed: 02.03.2021).

Liu N., Tang Q., Zhang J., Fan W., Liu J. A hybrid forecasting model with parameter optimization for short-term load forecasting of micro-grids. *Applied Energy*, 2014, vol. 129, pp. 336–345.

Quayle R. G., Steadman R. G. The Steadman wind chill: An improvement over present scales. *Weather and Forecasting*, 1998, vol. 13, iss. 4, pp. 1187–1193.

Rajan D. V., Mallick S., Thakur S. S. An efficient approach for short-term load forecasting using historical data. *International Journal of Engineering Research & Technology (IJERT)*, 2012, vol. 1, iss. 3. Available at: <https://goo-gl.ru/zizzs> (accessed: 02.03.2021).

Сведения об авторах

Станислав Олегович Хомутов – доктор технических наук, профессор; <https://orcid.org/0000-0002-8430-9384>, homutov.so@yandex.ru, Алтайский государственный

технический университет им. И. И. Ползунова (д. 46, пр-т Ленина, 656038 г. Барнаул, Россия); **Stanislav O. Khomutov** – Doctor of Technical Sciences, Professor; <https://orcid.org/0000-0002-8430-9384>, homutov.so@yandex.ru, Polzunov Altai State Technical University (46, Lenin pr., 656038 Barnaul, Russia).

Николай Александрович Серебряков – аспирант; <https://orcid.org/0000-0001-7428-7364>, na_serebryakov@altke.ru, Алтайский государственный технический университет им. И. И. Ползунова (д. 46, пр-т Ленина, 656038 г. Барнаул, Россия); **Nikolay A. Serebryakov** – Postgraduate student; <https://orcid.org/0000-0001-7428-7364>, na_serebryakov@altke.ru, Polzunov Altai State Technical University (46, Lenin pr., 656038 Barnaul, Russia).

Заявленный вклад авторов: все авторы сделали эквивалентный вклад в подготовку публикации. Авторы заявляют об отсутствии конфликта интересов.

Contribution of the authors: the authors contributed equally to this article. The authors declare no conflicts of interests.

Статья поступила в редакцию 14.05.2021; одобрена после рецензирования 01.06.2021; принята к публикации 16.06.2021.

The article was submitted 14.05.2021; Approved after reviewing 01.06.2021; Accepted for publication 16.06.2021.